

---

# A Unified Approach to Interpreting Model Predictions

---

**Scott M. Lundberg**

Paul G. Allen School of Computer Science  
University of Washington  
Seattle, WA 98105  
slund1@cs.washington.edu

**Su-In Lee**

Paul G. Allen School of Computer Science  
Department of Genome Sciences  
University of Washington  
Seattle, WA 98105  
suinlee@cs.washington.edu

# Abstract

---

## 왜 SHAP인가?

- 복잡한 모델은 예측 정확도가 높지만 개별 예측의 근거를 이해하기 어렵다
- 기존 설명 방법들의 관계가 명확하지 않아 상황에 맞는 방법을 선택하기 어렵다

## 핵심 기여

- 여섯 가지 기존 방법을 하나의 가법적 특성 기여도 모형으로 통합한다
- 세 가지 바람직한 성질을 모두 만족하는 유일한 해가 Shapley value임을 보인다
- Kernel SHAP과 Deep SHAP으로 계산 효율성과 사람의 직관에 대한 일치도를 높인다

**SHAP은 하나의 예측에 대해 각 특성의 기여도를 계산한다**

# Introduction

## 해석 가능성의 문제

- 단순한 모델은 해석하기 쉽지만 예측 성능이 낮을 수 있다
- 앙상블과 딥러닝에는 예측을 대신 설명할 단순한 국소 설명 모델이 필요하다
- 예측 설명은 모델에 대한 신뢰와 개선 방향을 제공한다

## 논문의 전개

- 1 여섯 가지 방법을 하나의 설명 모델로 통합
- 2 세 가지 성질을 만족하는 유일한 해를 증명
- 3 효율적인 SHAP 근사 방법을 제안하고 실험으로 평가

복잡한 모델  $f(x)$   $\rightarrow$  해석 가능한 설명  $g(z')$

# Additive Feature Attribution Methods

$$g(z') = \phi_0 + \sum_{i=1}^M \phi_i z'_i$$

Equation (1)

## 기호의 의미

- $z'_i \in \{0,1\}$ : 단순화된 특성  $i$ 의 포함 여부
- $\phi_0$ : 아무 특성 정보가 없을 때의 기준 예측값
- $\phi_i$ : 현재 예측에 대한 특성  $i$ 의 기여도

## 국소 설명

- 설명 모형  $g$ 는 관측치  $x$  주변에서 원래 모형  $f$ 를 근사한다
- 기준값과 모든 특성 기여도의 합이 설명하려는 예측값이 된다
- LIME, DeepLIFT, LRP와 세 가지 Shapley 방법이 이 구조를 공유한다

# LIME, DeepLIFT, and LRP

## LIME

- 관측치 주변에서 국소 선형 모델을 적합
- 교란된 이전 입력을 사용
- Kernel과 penalty를 경험적으로 선택

## DeepLIFT

- 각 입력을 기준값(reference value)과 비교
- 기여도의 합은  $f(x) - f(r)$
- 기준값은 정보가 없는 입력을 의미

$$\sum_{i=1}^n C_{\Delta x_i \Delta_0} = \Delta_0$$

and  $\phi_0 = f(r)$

## LRP

- 출력의 관련도(relevance)를 입력까지 역전파
- 기준 활성값이 0인 DeepLIFT와 동등
- 동일한 가법적 설명 구조를 사용

# Classic Shapley Value Estimation

$$\phi_i = \sum_{S \subseteq F - (i)} \frac{|S|! (|F| - |S| - 1)!}{|F|!} \left[ f_{S \cup (i)}(x_{S \cup (i)}) - f_{S(x_S)} \right]$$

Equation (4)

## 연합 관점(Coalition view)

- 특성을 예측값이라는 보상을 나누는 게임의 참여자로 본다
- 특성  $i$ 가 가능한 모든 부분집합  $S$ 에 합류할 때의 효과를 계산한다
- 모든 특성 순서에서의 한계 기여도(marginal contribution)를 가중 평균한다

## 기존 추정 방법

- Shapley regression values는 특성 부분 집합마다 모델을 다시 학습한다
- Shapley sampling은 일부 순서를 표본추출하여 완전 탐색을 피한다
- Quantitative Input Influence도 거의 같은 표본추출 방식을 사용한다

# Three Desirable Properties

---

- |   |                |                                           |                            |
|---|----------------|-------------------------------------------|----------------------------|
| 1 | Local accuracy | $f(x) = \varphi_0 + \sum_i \varphi_i$     | 기여도의 합이 실제 예측값과 정확히 일치     |
| 2 | Missingness    | $x'_i = 0 \Rightarrow \varphi_i = 0$      | 존재하지 않는 특성의 기여도는 0         |
| 3 | Consistency    | 한계 효과 증가 $\Rightarrow \varphi_i$ 감소<br>불가 | 모델의 의존도가 커지면 중요도가 감소할 수 없음 |
- 

신뢰할 수 있는 가법적 설명이 보존해야 할 세 가지 조건

# Unique Additive Explanation

## Theorem 1

Local accuracy, Missingness, Consistency를 모두 만족하는 가법적 설명은 하나뿐이다


$$\phi_{i(f,x)} = \sum_{z' \subseteq x'} \frac{|z'|! (M - |z'| - 1)!}{M!} \left[ f_{x(z')} - f_{x(z'-i)} \right]$$

Equation (8): the Shapley value

- 이 결과는 협력 게임 이론(cooperative game theory)의 Shapley value에서 도출된다
- Shapley value가 아닌 가법적 방법은 Local accuracy 또는 Consistency를 위반할 수 있다
- SHAP은 이 유일한 값을 여러 설명 방법이 근사해야 할 공통 기준으로 사용한다



# SHAP Values



$$f_{x(z')} = E[f(z) | z_S]$$

Figure 1

- 기준값  $E[f(z)]$ 는 아무 특성 정보가 없을 때의 평균 예측이다
- $\phi_i$ 는 특성  $i$ 를 조건으로 알게 되었을 때 기대 예측값이 변하는 정도다
- 비선형 모델이나 종속된 특성에서는 특성을 추가하는 순서가 결과에 영향을 준다
- SHAP은 가능한 모든 특성 순서에서 계산한 기여도를 평균한다

# Kernel SHAP

## 가중 선형회귀




Figure 2A

$$\pi_{x'}(z') = \frac{M-1}{\binom{M}{|z'|} |z'| (M-|z'|)}$$

- Shapley kernel은 LIME의 경험적 가중치를 이론적으로 결정된 가중치로 바꾼다
- 공집합과 전체집합에 무한대 가중치를 주어 기준값과 Local accuracy를 강제한다
- 하나의 회귀에서 모든 SHAP value를 함께 추정해 모델 평가 횟수를 줄인다

모델 불가지론적 방법: 모델 f의 입력과 출력만 있으면 적용 가능

# Model-Specific SHAP

## Linear SHAP

- 선형모형과 특성 독립성을 가정
- $\phi_i = w_i(x_i - E[x_i])$
- 회귀계수와 평균에서 떨어진 정도를 함께 반영

## Low-Order SHAP

- 특성 수  $M$ 이 작을 때 연합을 직접 열거
- 가중회귀 복잡도:  $O(2^M + M^3)$
- 조건부 기대값은 여전히 근사가 필요

## Max SHAP

- max 함수의 입력을 정렬하여 계산
- $O(M \cdot 2^M)$ 에서  $O(M^2)$ 으로 감소
- max-pooling 기여도를 빠르게 근사

모델 구조를 이용하면 계산은 빨라지지만 근사 과정에 추가 가정이 필요하다

# Deep SHAP




Figure 2B

## DeepLIFT와 Shapley value의 결합

- 단순한 신경망 구성요소의 SHAP value를 해석적으로 계산한다
- SHAP 기반 multiplier를 출력층에서 입력층 방향으로 역전파한다
- 구성요소의 경험적 선형화를 Shapley 기반 근사로 대체한다

$$m_{y_i f_3} = \sum_{j=1}^2 m_{y_i f_j} m_{x_j f_3}$$

$$\phi_{i(f_{3,y})} \approx m_{y_i f_3} (y_i - E[y_i])$$

딥러닝 모델을 위한 빠른 구성적 근사(compositional approximation)

# Computational Efficiency




Figure 3

- Kernel SHAP은 적은 함수 평가로 실제 Shapley value에 가까워진다
- 100개 중 3개 특성만 사용하는 희소모형에서 정규화 회귀의 장점이 뚜렷하다
- LIME의 kernel은 SHAP의 성질을 강제하지 않아 다른 기여도로 수렴할 수 있다

# User Studies and MNIST

## 사람의 기여도 판단




Figure 4A-B

- 두 문제 모두에서 SHAP의 기여도 배분이 사람들의 대표적인 판단과 일치한다
- LIME과 기존 DeepLIFT는 사람들이 기대한 배분과 다른 결과를 제시한다

## MNIST 클래스 설명




Figure 5A-B

- SHAP은 숫자 8과 3을 구분하는 핵심 픽셀을 가장 잘 식별한다
- SHAP 순위에 따라 픽셀을 제거했을 때 log-odds 변화가 가장 크다

# Conclusion

---

## 논문의 핵심 결과

- 여섯 가지 설명 방법을 하나의 가법적 특성 기여도 클래스로 통합한다
- Shapley value만 Local accuracy, Missingness, Consistency를 모두 만족한다
- Kernel SHAP은 모델 종류와 관계없이 효율적으로 기여도를 근사한다
- Deep SHAP은 신경망의 구성 구조를 이용해 계산 속도를 높인다

## 실험 결과와 향후 연구

- 단순한 배분 문제에서 SHAP이 사람의 설명과 가장 잘 일치한다
- SHAP이 선택한 픽셀은 MNIST 클래스를 효과적으로 구분한다
- 향후에는 가정을 줄인 모델별 알고리즘과 상호작용 효과 추정이 필요하다