

Simple and Scalable Predictive Uncertainty Estimation using Deep Ensembles

Balaji Lakshminarayanan, Alexander Pritzel, Charles Blundell

Advances in Neural Information Processing Systems 30 (NIPS 2017)

Nov 4th, 2017

오서영

Abstract

- 신경망(NN)에서 예측 불확실성을 정량화하는 것은 해결되지 않은 문제
- 베이지안 기반 신경망이 예측 불확실성 추정 분야에서 가장 좋은 성능을 보이지만 학습 과정이 복잡하고 계산 비용이 큼
- 이에 구현이 간단하고 병렬처리가 가능한 고품질의 Deep Ensembles 제안
- 분류와 회귀 문제, dataset shift, ImageNet 데이터셋에서의 제안 방법을 평가함

Introduction

- 목적

- 기존 신경망 학습 구조를 크게 변경하지 않고 예측 불확실성을 추정하는 방법 제안
- Calibration(보정)을 통해 예측 확률과 실제 값의 관측 빈도가 일치하는지 확인
- Domain shift나 out-of-distribution(분포 외 데이터)에 대한 예측 불확실성을 일반화

- 베이저안 기반 추정이란?

- NN(신경망)의 파라미터에 대해 사전분포를 설정하고 해당 파라미터에 대해 사후분포를 계산하여 예측 불확실성을 정량화 하는 방법
- Laplace 근사, MCMC, MC-dropout 등 다양한 근사 방법을 사용함
- 문제점
 - 추정의 품질이 사전분포에 의해 결정됨
 - 구현이 어렵고 학습 속도가 느림

- 이에 고품질의 불확실성 추정값을 제공하고 일반화가 가능한 pipeline을 제안

Introduction

- 기여점

1. NN에서 예측 불확실성 추정을 위한 간단하고 확장 가능한 방법을 제시함
 - Probabilistic NN 학습시 스코어링 규칙을 학습 기준으로 사용할 것을 제안함.
 - 또한 파이프라인에 앙상블과 적대적 학습(Adversarial training;AT)을 결합하여 효과를 조사함
2. 지도학습에서의 예측 불확실성 추정 품질 평가를 위한 방법을 제안함
 - 보정(calibration) 및 미지의 class에 대한 일반화 가능성을 평가함

- 독창성 & 의의

- 예측 불확실성 추정을 위해 딥앙상블의 성능을 근사 베이지안 방법과 비교한 논문은 해당 논문이 최초

Dataset

- Regression : toy datasets, real world datasets(protien, Year Prediction MSD 등)
- Classification : MNIST, SVHN, ImageNet
- Other : CIFAR-10, NotMNIST

평가지표

- negative log likelihood(NLL)
- Brier score : $BS = \frac{1}{K} \sum_{k=1}^K (t_k - p_{\theta}(y = k|x))^2$
- accuracy
- RMSE

Problem setup and High-level summary

• 문제 설정

- 학습자료: $D = \{x_n, y_n\}_{n=1}^N$
- 입력변수: $x_n \in \mathbb{R}^D$
- 분류: $y_n \in \{1, \dots, K\}$
- 회귀: $y_n \in \mathbb{R}$
- 목표: 조건부 예측분포 $p_\theta(y|x)$ 를 추정
→ 정확한 예측과 함께 해당 예측의 불확실성을 추정

• 방법

1. Scoring rule
 - 예측분포가 실제 자료의 분포에 가까워지도록 학습
2. Adversarial training
 - 입력값 주변에서 예측분포가 급격하게 변하지 않도록 평활화
3. Ensemble
 - 서로 다른 초기값을 가진 M개의 신경망 예측 분포를 결합

Proper scoring rules

- Proper scoring rule의 역할
 - 신경망이 점예측이 아닌 예측분포 $p_{\theta}(y|x)$ 를 출력하도록 학습
 - 예측분포가 실제 조건부 분포에 가까울수록 높은 점수를 부여
 - 학습시 scoring rule의 음수를 손실함수로 사용함
- Classification
 - $p_{\theta}(y = k|x), k = 1, \dots, K$
 - Softmax를 통해 클래스별 예측 확률을 출력
 - Scoring rule로 cross-entropy와 brier score 사용
- Regression
 - $y|x \sim N(\mu_{\theta(x)}, \sigma_{\theta}^2(x))$
 - Scoring rule : $-\log p_{\theta}(y|x) = \frac{1}{2} \log \sigma_{\theta}^2(x) + \frac{(y - \mu_{\theta(x)})^2}{2\sigma_{\theta}^2(x)}$

Adversarial training

- Adversarial example을 생성하여 원본 자료와 함께 학습

$$x' = x + \epsilon \text{sign}(\nabla_x l(\theta, x, y))$$

- 이를 통해 관측된 입력값 주변에서 예측분포가 급격히 변하는 현상 완화
- 또한 작은 입력 변화에 대해 예측분포가 갑자기 변하지 않도록 평활화하는 역할

Ensembles

- **Ensemble training**

- 동일한 구조의 신경망들을 독립적으로 학습하는 방법
- 분산 병렬연산에 적합한 randomization-based 접근법을 사용

→ 배깅과 다르게 개별 모델의 예측값 간 상관관계가 낮아지고, 각 모델의 성능이 높아지는 효과

- **결합**


- 분류 : $p_E(y|x) = \frac{1}{M} \sum_{m=1}^M p_{\theta_m}(y|x)$

- 회귀 : $\sigma_*^2 =$

$$\frac{1}{M} \sum_{m=1}^M \sigma_m^2 + \frac{1}{M} \sum_{m=1}^M (\mu_m - \mu_*)^2 =$$

모델별 예측분산 + 모델 간 평균차이

Regression on toy datasets



- $y = x^3 + \epsilon$, $\epsilon \sim N(0, 3^2)$ 을 따르는 분포에서 생성된 20개의 data로 학습
- 결과
 - MSE를 scoring rule로 학습한 모델보다 NLL 학습을 통한 모델이 관측자료의 분산을 직접 추정할 수 있어 예측 불확실성을 표현가능하게 함
 - 또한 앙상블을 적용하면 학습자료가 없는 영역에서 불확실성이 크게 증가함


Regression on real world datasets

Datasets	RMSE			NLL		
	PBP	MC-dropout	Deep Ensembles	PBP	MC-dropout	Deep Ensembles
Boston housing	3.01 ± 0.18	2.97 ± 0.85	3.28 ± 1.00	2.57 ± 0.09	2.46 ± 0.25	2.41 ± 0.25
Concrete	5.67 ± 0.09	5.23 ± 0.53	6.03 ± 0.58	3.16 ± 0.02	3.04 ± 0.09	3.06 ± 0.18
Energy	1.80 ± 0.05	1.66 ± 0.19	2.09 ± 0.29	2.04 ± 0.02	1.99 ± 0.09	1.38 ± 0.22
Kin8nm	0.10 ± 0.00	0.10 ± 0.00	0.09 ± 0.00	-0.90 ± 0.01	-0.95 ± 0.03	-1.20 ± 0.02
Naval propulsion plant	0.01 ± 0.00	0.01 ± 0.00	0.00 ± 0.00	-3.73 ± 0.01	-3.80 ± 0.05	-5.63 ± 0.05
Power plant	4.12 ± 0.03	4.02 ± 0.18	4.11 ± 0.17	2.84 ± 0.01	2.80 ± 0.05	2.79 ± 0.04
Protein	4.73 ± 0.01	4.36 ± 0.04	4.71 ± 0.06	2.97 ± 0.00	2.89 ± 0.01	2.83 ± 0.02
Wine	0.64 ± 0.01	0.62 ± 0.04	0.64 ± 0.04	0.97 ± 0.01	0.93 ± 0.06	0.94 ± 0.12
Yacht	1.02 ± 0.05	1.11 ± 0.38	1.58 ± 0.48	1.63 ± 0.02	1.55 ± 0.12	1.18 ± 0.21
Year Prediction MSD	8.88 ± NA	8.85 ± NA	8.89 ± NA	3.60 ± NA	3.59 ± NA	3.35 ± NA


- Deep Ensembles는 대부분의 자료에서 기존 방법과 유사하거나 더 낮은 NLL을 기록함
- 일부 데이터에서는 Deep Ensembles의 RMSE가 PBP, MC-dropout보다 높게 나타남
- 예측 불확실성을 반영하는 NLL에서는 전반적으로 경쟁력 있는 성능을 보임

Classification on MNIST, SVHN, ImageNet

- 목적
 - 앙상블 크기 M의 효과 평가
 - AT의 추가 효과 확인
 - MC-dropout과 불확실성 추정 성능 비교




(a) MNIST dataset using 3-layer MLP



(b) SVHN using VGG-style convnet

- 결과
 - M이 증가할수록 분류오차, NLL, Brier score가 전반적으로 감소함
 - Deep Ensembles는 같은 M에서 MC-dropout보다 우수한 성능
 - MNIST에서는 제안 모형이 일반 Ensemble보다 개선된 결과
 - SVHN에서는 AT의 효과가 M=1일때에는 나타났지만, M이 증가하면서 차이 감소

Uncertainty evaluation : test examples from know vs unknown classes



(a) MNIST-NotMNIST


(b) SVHN-CIFAR10

- Top row : known class
- Bottom row : unknown class

- ensemble size가 증가할수록 unknown class의 예측 엔트로피가 높은 쪽으로 이동해야 함
- MC-dropout의 결과에서는 대부분의 엔트로피가 0 근처에 위치함
- 반면 제안한 방법인 앙상블에 AT를 결합한 결과는 엔트로피가 일반 앙상블보다 빠르게 증가함

Accuracy as a function of confidence

- MNIST와 NotMNIST 데이터를 혼합하여 평가
- 모델이 일정 confidence 이상을 보인 표본만 남겨 accuracy를 계산
신뢰도 $p(y = \hat{y}|x) = \max_k p(y = k|x)$
- 신뢰도 임계값이 τ 일 때 $\max_k p(y = k|x) \geq \tau$ 인 표본만 선택하여 정확도를 계산



- 좋은 불확실성 추정
 - τ 가 증가할수록 정확도도 함께 증가
 - OOD 표본은 낮은 confidence
- 결과
 - Deep Ensemble은 τ 가 증가할수록 정확도가 비교적 안정적으로 증가함
 - MC-dropout은 높은 τ 에서도 낮은 정확도를 보임
 - 제안 모델이 일부 구간에서 가장 안정적인 결과를 보여 실제 의사결정 기준으로 더 유용함을 확인함

Discussion

- 예측 불확실성 정량화를 위해 간단하고 확장가능한 non-Bayesian 방법을 제안함
- 스코어링 규칙을 사용하여 신경망에서 주어진 x 에 대한 목표 y 의 모호성을 확인
- 앙상블과 AT를 결합하여 분포 외의 예제에 대한 강건성을 확보함
- 향후 연구
 - 앙상블에서의 train 간 병렬화가 가능하게 설계를 하였으므로 네트워크 예측에서 명시적 상관 관계를 제거하여 앙상블 간 다양성과 성능을 올릴 수 있음
 - 또한, 스택킹과 adaptive mixture of experts를 추가하여 성능을 올릴 수 있음
 - 메모리 제약이 있는 응용 프로그램에서 앙상블을 간단하게 축소하거나, multiple heads, snapshot ensembles, swapout 등과 같은 암묵적 앙상블에도 흥미