

mixup

Beyond Empirical Risk Minimization

ICLR 2018 paper review

핵심 질문

**학습 데이터를 맞추는 것만으로
정말 일반화가 보장될까?**

Hongyi Zhang, Moustapha Cisse, Yann N. Dauphin, David Lopez-Paz

Zhang et al., ICLR 2018, title/abstract

Abstract

- 기존 Empirical Risk Minimization(ERM) 기반 딥러닝 모델의 과적합(기억화) 및 적대적 공격 취약성을 극복하기 위한 데이터 증강 기법인 mixup 제안
- 문제 제기 (기존 딥러닝의 한계)
 - 학습 데이터를 그대로 외우는 기억화(memorization) 현상
 - 적대적 예제(adversarial examples)에 민감
- 제안하는 해결책 (mixup 기법)
 - 데이터 섞기(Convex Combination)
 - 선형 동작 유도
- 기대 효과 및 주요 성과
 - 일반화 성능 향상
 - 노이즈 및 공격에 강함
 - 학습 안정화

Introduction

- **기존 ERM(Empirical Risk Minimization)의 치명적 한계 지적**

- 현대 딥러닝은(2018 기준) 학습 데이터의 손실(Training Loss)을 0으로 만드는 ERM 패러다임에 의존
- 하지만 이 방식은 모델이 학습 데이터의 점(Data Points)만을 '**암기(Memorization)**'하게 만들어, 학습 데이터 구역을 조금만 벗어나도 불확실성 제어 능력이 무너지고 **적대적 공격(Adversarial Attack)**에 극도로 취약

- **Vicinal Risk Minimization (VRM) 개념으로의 확장**

- 학습 데이터 주변의 가상 영역(Vicinity)을 정의하여 학습시키는 VRM 원리를 설명
- 기존 VRM(가우시안 노이즈 주입 등)은 각 데이터 주변의 아주 좁은 영역만 다루어 큰 효과가 없었음을 짚고, mixup은 서로 다른 데이터 사이 전체를 잇는 대규모 보간 영역을 다루는 새로운 VRM 방식임을 강조

- **Occam's Razor (옥컴의 면도날) 관점의 단순함 강조**

- 코드 단 몇 줄만으로 구현 가능, 추가적인 계산 비용이 거의 들지 않는 뛰어난 효율성을 강조

Data

- **이미지 데이터 (Image Classification)**

- **ImageNet-2012**, : 1,000개 클래스, 약 130만 장의 학습 이미지 및 5만 장의 검증 이미지로 구성된 대규모 이미지 데이터셋
- **CIFAR-10**: 10개 클래스, 총 6만 장의 32×32 컬러 이미지 데이터셋
- **CIFAR-100**: 100개 클래스, 총 6만 장의 32×32 컬러 이미지 데이터셋

- **음성 데이터 (Speech Recognition)**

- **Google Commands Dataset**: 몇 천 명의 발화자가 단어(예: yes, no 등)를 다르게 발음한 1초 분량의 음성 샘플 6만 5천 개(총 30개 클래스)

- **표 데이터 (Tabular Data / UCI Repository)**

- **UCI Machine Learning Repository**: 비이미지/일반 분류 문제를 다루기 위해 추출한 6개의 데이터셋
 - * Abalone (전복 연령 예측)
 - * Arcene (암 판별 유전자/프로테오믹스 데이터)
 - * Arrhythmia (부정맥 진단 데이터)
 - * Htru2 (펄서/신세포 후보 식별 데이터)
 - * Iris (붓꽃 품종 분류)
 - * Phishing (피싱 웹사이트 감지)

- **Synthetic / Toy Datasets**

- **2D Toy Datasets**: GAN 학습 안정성 시각화를 위한 2차원 가상 분포 데이터 (도넛 형태 및 격자 형태의 분포)

주요 수식

expected risk (기대 위험)

$$R(f) = \int \ell(f(x), y) dP(x, y)$$

입력 x 와 정답 y 의 실제 joint probability distribution $P(X, Y)$ 상에서 손실함수 ℓ 의 평균값을 의미
이 값을 최소화하는 모델 $f(x)$ 를 찾는 것이 머신러닝의 목적

하지만, 실제 분포 P 는 모르므로, 학습 데이터의 **empirical distribution**으로 대체

Empirical Distribution & Empirical Risk

$$P_\delta(x, y) = \frac{1}{n} \sum_{i=1}^n \delta(x = x_i, y = y_i)$$

데이터가 존재하는 지점 (x_i, y_i) 에만 확률(Dirac delta)을 $1/n$ 씩 부여한 관측 분포
→ 우리가 수집한 n 개의 표본 데이터 지점에만 확률을 몰아준 경험적(실험적) 확률 분포

Empirical Risk Minimization, ERM

$$R_\delta(f) = \int \ell(f(x), y) dP_\delta(x, y) = \frac{1}{n} \sum_{i=1}^n \ell(f(x_i), y_i)$$

모델이 주어진 학습 데이터 n 개에 대해 낸 손실의 평균값입니다. 모델 파라미터가 매우 많으면 이 오차만 줄이려다가 데이터를 그대로 외워버리는(memorization) 문제 발생 → **‘과적합(Overfitting)’ 또는 ‘일반화 성능부족’ 현상**

주요 수식

Vicinal Risk Minimization (VRM, 이웃 위험 최소화)

$$P_\nu(\tilde{x}, \tilde{y}) = \frac{1}{n} \sum_{i=1}^n \nu(\tilde{x}, \tilde{y} | x_i, y_i)$$

ERM의 한계를 극복하기 위해, 각 학습 데이터 샘플 (x_i, y_i) 주변에 이웃 분포 ν 를 설정하고 그 주변 공간까지 고려하여 위험을 최소화하는 방식

$$R_\nu(f) = \frac{1}{m} \sum_{i=1}^m \ell(f(\tilde{x}_i), \tilde{y}_i)$$

데이터 주변 영역(vicinity)에서 가상의 샘플 $\tilde{x}, \tilde{y}$ 를 생성해 데이터셋을 확장하고, 이 가상 데이터들에 대한 평균 손실 R_ν 를 최소화.
일반적인 데이터 증강(Data Augmentation) 방식의 이론적 바탕

n : 원본 학습 데이터의 총 개수 (Original dataset size).

m : VRM 이웃 분포 ν 를 통해 새로 뽑아낸 **가상 샘플(Virtual examples)의 총 개수** (Augmented dataset size).

데이터 증강을 거쳤으므로 보통 $m \geq n$

•ERM:

- 분포: P_δ : 오직 관측된 학습 데이터 지점에만 확률 $1/n$ 부여
- 위험: $R_\delta(f)$: 오직 관측된 학습 데이터에서의 평균 오차

•VRM:

- 분포: P_ν : 학습 데이터 **주변 공간**까지 확장된 확률 분포 → **데이터 점 바로 옆 아주 좁은 원형 영역만 이웃**
- 위험: $R_\nu(f)$: 확장된 주변 공간 가상 데이터에서의 평균 오차


주요 수식

mixup Vicinal Distribution (mixup의 이웃 분포)

$$\mu(\tilde{x}, \tilde{y} | x_i, y_i) = \frac{1}{n} \sum_j^n \mathbb{E}_{\lambda} [\delta(\tilde{x} = \lambda \cdot x_i + (1 - \lambda) \cdot x_j, \tilde{y} = \lambda \cdot y_i + (1 - \lambda) \cdot y_j)]$$

mixup 핵심 수식

$\tilde{x}, \tilde{y}$ 를 만들어낼 때, 임의의 두 학습 샘플 (x_i, y_i) 와 (x_j, y_j) 를 선택하여 비율 λ 만큼 내분(선형보간) 한 지점을 이웃 확률 공간으로 지정함



$$\tilde{x} = \lambda x_i + (1 - \lambda) x_j,$$

$$\tilde{y} = \lambda y_i + (1 - \lambda) y_j,$$

where (x_i, y_i) and (x_j, y_j) are two feature-target vectors drawn at random from the training data, and $\lambda \in [0, 1]$. The *mixup* hyper-parameter α controls the strength of interpolation between feature-target pairs, recovering the ERM principle as $\alpha \rightarrow 0$.

주요 수식

Vanilla GAN 목적 함수

$$\max_g \min_d \mathbb{E}_{x,z} \ell(d(x), 1) + \ell(d(g(z)), 0)$$

판별자 d : 실제 데이터 x 에 대해서는 1(진짜), 생성된 가짜 데이터 $g(z)$ 에 대해서는 0(가짜)을 출력하도록 손실 l 을 최소화

생성자 g : 판별자 d 가 가짜 데이터 $g(z)$ 를 진짜(1)로 판단하게끔 만들어 판별자의 손실을 최대화(자신의 손실 최소화)

mixup GAN 목적 함수

$$\max_g \min_{d, \lambda} \mathbb{E}_{x,z} \ell(d(\lambda x + (1 - \lambda)g(z)), \lambda)$$

기존 GAN 학습 과정에 mixup 원리를 적용하여 판별자 학습을 정규화한 목적 함수

큰 신경망은 학습 데이터를 맞히지만, 외부에서는 흔들릴 수 있다

논문은 **ERM**만으로 설명하기 어려운 두 현상을 출발점으로 삼습니다.

1. Memorization 학습 데이터 암기

- 큰 신경망은 random label도 외울 수 있음
- training loss가 낮아도 일반화 보장은 아님

2. Adversarial sensitivity 작은 변화에 취약

- 사람이 거의 못 느끼는 perturbation에도 예측 변화
- gradient가 큰 방향에서는 작은 변화가 큰 손실 변화로 연결

공통 질문: 학습 샘플 주변과 샘플 사이에서 모델은 어떻게 행동해야 하는가?

VRM은 한 샘플 주변의 가상 샘플까지 학습하려는 관점이다

Data augmentation은 ERM보다 넓은 영역을 학습시키려는 VRM의 사례입니다.



$$P_{\nu}(\tilde{x}, \tilde{y}) = \frac{1}{n} \sum_{i=1}^n \nu(\tilde{x}, \tilde{y} | x_i, y_i)$$

- 장점: training distribution의 support를 넓힘
- 한계 1: 어떤 변환이 타당한지 domain knowledge 필요
- 한계 2: 보통 label을 그대로 유지
- 한계 3: 서로 다른 class 사이의 vicinity를 직접 다루지 않음

mixup은 vicinity를 “두 샘플 사이의 선형 보간”으로 정의한다.

mixup의 핵심: 입력과 정답을 같은 비율로 섞는다

두 원본 샘플을 뽑고, 입력과 label을 같은 λ 로 convex combination합니다.

$$(x_i, y_i)$$

예: cat [1,0]

$\lambda \in [0,1] \rightarrow$

$$\begin{aligned}\tilde{x} &= \lambda x_i + (1 - \lambda)x_j \\ \tilde{y} &= \lambda y_i + (1 - \lambda)y_j\end{aligned}$$

$$(x_j, y_j)$$

예: dog [0,1]

- $\tilde{x}$: 새로 만든 virtual input
- $\tilde{y}$: hard label이 아니라 soft target
- 같은 λ 를 쓰는 것이 mixup의 핵심

숫자 예시
 $\lambda = 0.7$
 $\tilde{y} = 0.7[1,0] + 0.3[0,1] = [0.7, 0.3]$

고양이 형태가 70% 정도 진하게 보이고, 그 위에
개 형태가 30% 정도 반투명하게 겹쳐
보이는(Ghost/Overlay) 가상 이미지 생성

α 는 mixup이 원본에 가까울지, 중간점을 많이 만들지 조절한다

$\lambda \sim \text{Beta}(\alpha, \alpha)$: α 가 interpolation strength를 조절합니다.

$\alpha \rightarrow 0$

λ 가 0 또는 1 근처
virtual sample이 원본과 거의 같음
ERM으로 수렴

$\alpha = 1$

λ 가 0-1에서 균등
다양한 중간점을 고르게 생성
CIFAR 실험에서 사용

큰 α

λ 가 0.5 근처
강한 섞기가 많아짐
너무 크면 underfitting 가능


수식의 의미

- Beta 분포는 0과 1 사이의 값을 샘플링하기 위한 분포
- λ 가 클수록 첫 번째 샘플의 비중이 커짐
- 논문은 ImageNet에서 $\alpha \in [0.1, 0.4]$ 가 ERM보다 좋았고, 큰 α 에서는 underfitting을 언급

주의: α 는 “크면 클수록 좋은 값”이 아니라 bias-variance trade-off를 조절하는 값입니다.

Beta(α, α) 분포 모양 비교

λ 별 확률밀도 $f(\lambda)$



학습 절차는 minibatch를 섞고 같은 loss로 업데이트하는 방식이다

모델 구조를 바꾸기보다, batch가 모델에 들어가기 직전에 x 와 y 를 바꿉니다.

```
lam = numpy.random.beta(alpha, alpha)
x = lam * x1 + (1 - lam) * x2
y = lam * y1 + (1 - lam) * y2
loss(net(x), y).backward()
optimizer.step()
```

1. 두 minibatch 준비

2. $\lambda \sim \text{Beta}(\alpha, \alpha)$ 샘플링

3. x 와 y 를 같은 λ 로 섞음


4. 기존 loss로 update

- few lines of code
- architecture 변경 없음
- optimizer 변경 없음
- 계산 overhead가 작음

구현 핵심: 입력을 섞으면 정답도 같은 비율로 섞는다.

mixup은 훈련 샘플 사이에서 더 부드러운 결정 경계를 만든다

Figure 1b는 class 사이에서 예측 확률이 어떻게 변하는지 보여줍니다.




- ERM: 학습 점을 맞히지만 중간 예측이 더 급하게 변할 수 있음
- mixup: class 사이 전환이 더 넓고 부드러움
- 해석: "샘플 사이에서도 단순한 선형 행동"을 선호

보야 할 점
파란 음영의 경계가 왼쪽보다 오른쪽에서 더 부드럽게 이어진다.


Green: Class 0 · Orange: Class 1 · Blue shading: $p(y=1|x)$

Figure 2: 샘플 사이의 miss와 gradient norm이 줄었다

같은 architecture를 ERM과 mixup으로 학습한 뒤, 두 샘플 사이를 따라 평가했습니다.



왼쪽: $x = \lambda x_i + (1 - \lambda)x_j$ 에서 예측이 $\{y_i, y_j\}$ 중 어디에도 속하지 않으면 miss



오른쪽: 입력에 대한 loss gradient norm. 작을수록 작은 입력 변화에 덜 민감한 방향

결론: mixup은 샘플 사이에서 miss와 gradient norm을 모두 낮췄다.

ImageNet에서는 여러 대형 모델에서 Top-1 error가 낮아졌다

Table 1 핵심 재구성: ERM 대비 mixup의 validation Top-1 error 비교

Model (90 epochs)	ERM	mixup	Δ Top-1	Top-5 mixup
ResNet-50	23.5	23.3	-0.2	6.6
ResNet-101	22.1	21.5	-0.6	5.6
ResNeXt-101 32×4d	21.2	20.7	-0.5	5.3
ResNeXt-101 64×4d	20.4	19.8	-0.6	4.9

Model (200 epochs)	ERM	mixup	Δ Top-1	Top-5 mixup
ResNet-50	23.6	22.1	-1.5	6.1
ResNet-101	22.0	20.8	-1.2	5.4
ResNeXt-101 32×4d	21.3	20.1	-1.2	5.0


- ImageNet-2012: 1.3M training images, 50K validation images, 1000 classes
- 대형 모델과 긴 학습에서 개선 폭이 더 커지는 경향을 논문이 언급
- α : ResNet은 0.2, ResNeXt는 0.4 사용

읽는 법: Top-1 error는 낮을수록 좋습니다. Δ Top-1은 mixup - ERM입니다.

CIFAR-10/100에서는 모든 비교 모델에서 test error가 감소했다

Figure 3의 핵심: CIFAR-10/100에서 mixup은 세 모델 모두에서 낮은 test error를 보였습니다.

Dataset	Model	ERM	mixup
CIFAR-10	PreAct ResNet-18	5.6	4.2
CIFAR-10	WideResNet-28-10	3.8	2.7
CIFAR-10	DenseNet-BC-190	3.7	2.7
CIFAR-100	PreAct ResNet-18	25.6	21.1
CIFAR-100	WideResNet-28-10	19.4	17.5
CIFAR-100	DenseNet-BC-190	19.0	16.8



Right: DenseNet-190 baseline vs mixup test error evolution

봐야 할 점: 표에서는 모든 모델에서 감소, 그래프에서는 mixup 곡선이 더 낮게 수렴

Speech와 tabular data에서도 data-agnostic 가능성을 시험했다

이미지 변환 지식 없이 speech spectrogram과 tabular data에도 적용했습니다.

Google Commands	Method	Validation	Test
LeNet	ERM	9.8	10.3
LeNet	mixup $\alpha=0.1$	10.1	10.8
LeNet	mixup $\alpha=0.2$	10.2	11.3
VGG-11	ERM	5.0	4.6
VGG-11	mixup $\alpha=0.1$	4.0	3.8
VGG-11	mixup $\alpha=0.2$	3.9	3.4

UCI dataset	ERM	mixup	결과
Abalone	74.0	73.6	개선
Arcene	57.6	48.0	개선
Arrhythmia	56.6	46.3	개선
Htru2	2.0	2.0	동률
Iris	21.3	17.3	개선
Phishing	16.3	15.2	개선

* LeNet: 손글씨 숫자 이미지(MNIST)를 인식하기 위한 초기 CNN 모델/데이터셋 환경

해석: VGG-11과 UCI 대부분에서는 개선. 그러나 LeNet처럼 악화된 사례도 있으므로 “항상 개선”은 아님.

LeNet-5(MNIST) 실험에서 mixup의 효과가 미미했던 이유는, MNIST가 이미 ERM만으로도 99% 이상의 높은 성능을 내는 단순한 데이터셋이기 때문입니다. 이미 과적합 문제가 없는 단순 도메인에서는 mixup의 강점인 '결정 경계 평활화' 효과가 크게 발휘되지 못한다.

Corrupted label 실험은 “외우기”를 직접 시험한다

training label 일부를 일부러 random label로 바꾸고, 모델이 이를 외우는지 봅니다.



ERM의 위험
한 점에서 잘못된 label까지
맞히도록 학습될 수 있음

mixup의 압력
잘못된 label이 여러 샘플과 섞여
암기하기 어려워짐

중요한 읽는 법: corrupted label training error가 높으면
random label을 덜 외운 것으로 해석할 수 있습니다.

Table 2: mixup은 random label 암기를 억제하고 test error를 낮췄다

Table 2 핵심 재구성: best/last test error와 corrupted label training error

Corruption	Method	Best test	Last test	Train real	Train corrupted
20%	ERM	12.7	16.6	0.05	0.28
20%	mixup $\alpha=8$	5.9	6.4	2.27	86.32
50%	ERM	18.8	44.6	0.26	0.64
50%	mixup $\alpha=32$	11.3	12.7	5.84	85.71
80%	ERM	36.5	73.9	0.62	0.83
80%	mixup $\alpha=32$	25.3	30.9	18.92	85.44


- 50% corruption에서 ERM last test error가 44.6까지 악화
- ERM은 corrupted label training error가 0.64로 낮아 random label까지 암기
- mixup은 corrupted label training error를 높게 유지하면서 test error를 낮춤

→ 랜덤 라벨을 외우지 않았다는 방향의 근거

핵심 해석: mixup은 “진짜 패턴”은 학습하되 random label memorization을 억제하는 regularization으로 작동했다.

Adversarial example 실험은 작은 입력 변화에 대한 민감도를 본다

Adversarial example = 정상 입력 + 작은 perturbation으로 모델을 틀리게 만드는 입력



구분	공격 샘플 생성 방식	논문 설정
White-box	평가 모델 자신의 gradient 사용	FGSM, I-FGSM
Black-box	다른 ERM 모델에서 만든 공격 사용	FGSM, I-FGSM

- I-FGSM: 10 iterations with equal step size
- ResNet-101 ImageNet 모델 사용
- 목표: mixup이 입력 변화 민감도를 낮추는지 확인

Table 3: FGSM과 black-box 공격에서는 error가 낮아졌지만 한계도 있다

Table 3 핵심: error는 낮을수록 좋습니다.

White-box	ERM	mixup
Top-1 FGSM	90.7	75.2
Top-1 I-FGSM	99.9	99.6
Top-5 FGSM	63.1	49.1
Top-5 I-FGSM	93.4	95.8

Black-box	ERM	mixup
Top-1 FGSM	57.0	46.0
Top-1 I-FGSM	57.3	40.9
Top-5 FGSM	24.8	17.4
Top-5 I-FGSM	18.1	11.8

보야 할 점: FGSM과 black-box 공격에서는 mixup error가 낮다.

한계: white-box I-FGSM에서는 ERM 99.9, mixup 99.6으로 둘 다 매우 취약하다.

정확한 결론: adversarial robustness를 해결한 것이 아니라, 일부 공격에서 추가 비용 없이 완화 효과를 보였다.


GAN에서는 real과 fake 사이를 섞어 discriminator를 부드럽게 만든다

GAN의 discriminator에도 “중간에서 선형적으로 변하라”는 압력을 줄 수 있습니다.

기존 GAN
real $x \rightarrow$ target 1
fake $g(z) \rightarrow$ target 0

mixup GAN
input = $\lambda x + (1 - \lambda)g(z)$
target = λ

objective
 $\max_g \min_d E \ell(d(\lambda x + (1 - \lambda)g(z)), \lambda)$



$\nabla_x \mathcal{L}_G \propto \frac{\nabla_x D(x)}{D(x)}$ 구조에서, **ERM**은 $\nabla_x D \rightarrow \infty$ (폭발) 또는 $D(x) \rightarrow 0$ (소실)을 유발,
mixup은 $\nabla_x D \approx \text{const.}$ 및 $D(x) \approx \lambda$ 를 강제하여 기울기를 상수로 안정화

Ablation: random pair + all classes + target mixing이 핵심이었다

Table 5 핵심 재구성: CIFAR-10 / PreAct ResNet-18 / median test error of last 10 epochs

Method	Specification	Modified		Weight decay	
		Input	Target	10^{-4}	5×10^{-4}
ERM		✗	✗	5.53	5.18
mixup	AC + RP	✓	✓	4.24	4.68
	AC + KNN	✓	✓	4.98	5.26
mix labels and latent representations (AC + RP)	Layer 1	✓	✓	4.44	4.51
	Layer 2	✓	✓	4.56	4.61
	Layer 3	✓	✓	5.39	5.55
	Layer 4	✓	✓	5.95	5.43
	Layer 5	✓	✓	5.39	5.15
mix inputs only	SC + KNN (Chawla et al., 2002)	✓	✗	5.45	5.52
	AC + KNN	✓	✗	5.43	5.48
	SC + RP	✓	✗	5.23	5.55
	AC + RP	✓	✗	5.17	5.72
label smoothing (Szegedy et al., 2016)	$\epsilon = 0.05$	✗	✓	5.25	5.02
	$\epsilon = 0.1$	✗	✓	5.33	5.17
	$\epsilon = 0.2$	✗	✓	5.34	5.06
mix inputs + label smoothing (AC + RP)	$\epsilon = 0.05$	✓	✓	5.02	5.40
	$\epsilon = 0.1$	✓	✓	5.08	5.09
	$\epsilon = 0.2$	✓	✓	4.98	5.06
	$\epsilon = 0.4$	✓	✓	5.25	5.39
add Gaussian noise to inputs	$\sigma = 0.05$	✓	✗	5.53	5.04
	$\sigma = 0.1$	✓	✗	6.41	5.86
	$\sigma = 0.2$	✓	✗	7.16	7.24

- AC: all classes, RP: random pairs
- 기본 mixup은 input과 target을 함께 섞음
- input만 섞거나 label smoothing만 쓰는 경우보다 성능이 뛰어남
- 이 깊은 공간에서 단순히 두 특징값을 단순 선형 보간 해 버리면, 실제 데이터 분포를 벗어난 의미 없는 노이즈(Out-of-distribution)가 되어버리기 때문에 Layer 4에서는 5.95%까지 성능이 크게 떨어짐

Manifold Mixup (ICML 2019) 논문의 핵심 아이디어 고정된 한개 층만 믹스하지 않고, 학습 도중 무작위 층(Random Layer)을 선택해서 믹스하면 고차원 매니폴드 공간 전체가 예쁘게 평탄화(Flattening)되어 성능이 더 올라간다

핵심 결론: 입력 이미지와 정답 라벨을 동시에, 서로 다른 클래스끼리 무작위로 섞는 원본 mixup 방식(AC+RP)이 은닉층 보간, 단순 노이즈 주입, 라벨 스무딩 등 다른 모든 변형 기법보다 성능이 우수함

논문의 위치와 한계: 단순하지만 α 의 sweet spot 이론은 부족하다

mixup은 data augmentation(데이터 증강)과 soft label($\leftrightarrow$ hard label)의 장점을 결합하지만, 해석과 적용에 한계

방법	공통점	mixup과의 차이
Data augmentation	가상 데이터 생성	변환 설계에 domain knowledge가 필요
SMOTE/feature interpolation	샘플 보간	주로 같은 class/nearest neighbors 중심
Label smoothing	soft target 사용	입력 위치와 label 변화가 직접 연결되지 않음
mixup	input + target interpolation	같은 λ 로 두 공간을 함께 연결

- 모든 dataset(UCI ML Repository-Thyroid, Arrhythmia)/model(ResNet-101 / DenseNet-168)에서 항상 개선된 것은 아님
- white-box I-FGSM에는 거의 강하지 않음
- α 가 커지면 training error 증가, generalization gap 감소 경향
- 적절한 α sweet spot을 설명하는 완전한 이론은 부족

저자들이 남긴 질문: regression, structured prediction, semi-supervised, reinforcement learning 등으로 확장 가능한가?

확장 논문 List

- C-Mixup: Improving Generalization in Regression via Continuous Mixup (NeurIPS 2022)
- SeqMix: Augmenting Sentence Sequences via Mixup for Sequence Labeling (EMNLP 2020)
- MixMatch: A Holistic Approach to Semi-Supervised Learning (NeurIPS 2019)
- Mixreg: Data Augmentation for Visual Reinforcement Learning (ICML 2021)

독자 질문: 선형 보간 관점에서 내적을 이용한 개념이 있다면 외적을 이용한 개념도 존재한가?

CutMix: Regularization Strategy to Train Strong Classifiers (ICCV 2019): 1차원 선형 결합이 아닌 2차원 가로*세로 공간 영역(Area)을 다루는 방식

핵심 정리: mixup은 샘플 사이의 행동을 학습 원리로 만든다

이 논문은 “더 많은 데이터를 만든다”보다 “샘플 사이의 행동을 규정한다”에 가깝습니다.

1

ERM은 학습 지점에서만
평균 손실을 직접 최소화한다.

2

mixup은 두 입력과 두 label을
같은 λ 로 섞는다.

$$\tilde{x} = \lambda x_i + (1 - \lambda)x_j$$

$$\tilde{y} = \lambda y_i + (1 - \lambda)y_j$$

3

샘플 사이에서 선형적이고
부드러운 행동을 유도한다.

핵심 질문

학습 데이터를 맞추는 것만으로
정말 일반화가 보장될까?

mixup의 답:
샘플과 샘플 사이의 행동도 학습시킨다

Q&A