


Proximal Policy Optimization Algorithms

John Schulman et al. 2017, arXiv preprint

Background

- 강화학습
- State, Action, Reward, Return, Policy, Advantage



Background


개념	의미
$s_t(state)$	지금 어떤 상황에 있는지
$a_t(action)$	현재 상태에서 어떤 행동을 할 것인지
$r_t(reward)$	지금 행동 직후 받은 보상
$G_t(return)$	앞으로 받을 누적 보상
$\pi_\theta(a s)(policy)$	각 state에서 어떤 action을 할지 결정하는 규칙
$A(s,a)(advantage)$	이 행동이 평균적인 행동보다 얼마나 좋은가

$$\hat{g} = \hat{E}_t[\nabla_\theta \log \pi_\theta(a_t|s_t) \hat{A}_t]$$

$A_t > 0$ 이면(좋은 행동) 확률 높이고
 $A_t < 0$ 이면(나쁜 행동) 확률 낮추기

문제는 얼마나 많이 바꾸는지

Background



State: (1,1)

Action: 오른쪽으로 한칸 이동

Reward: -1점

Return: +5점


Policy: 오른쪽 0.6, 아래 0.4

Abstract

- PPO(근접 정책 최적화)는 환경에서 데이터를 수집한 뒤 surrogate objective(대리 목적함수)를 최적화하는 새로운 policy gradient(정책 경사) 방법을 제안한다.
- 기존 TRPO(신뢰영역 정책 최적화)보다 구현이 단순하면서도, 같은 데이터를 여러 epoch동안 minibatch로 학습할 수 있어 표본 효율성을 높인다.
- 로봇 제어와 Atari 게임 실험에서 기존 online policy gradient(온라인 정책 경사) 방법보다 좋은 성능을 보이며, 성능·단순성·학습 효율 사이의 균형을 보였다.

Introduction

- TRPO
 - 얼마나 많이 움직여도 안전한가(0.25- $\rightarrow$ 0.99)
 - 이전 policy와 너무 달라지지 말자
- 왜 복잡한가
 - Gradient 계산, 켈레경사법, KL 측정 등의 과정이 필요하기 때문




Method

- Clipping

$$L^{clip} = \hat{E}_t[\min(r_t A_t, \text{clip}(r_t, 1 - \epsilon, 1 + \epsilon) A_t)]$$

$r_t A_t$ = 정책이 얼마나 바뀌었는지 $\times$ 그 행동이 얼마나 좋았는지



$\epsilon = 0.2, A_t = 2, r_t = 1.5$
 $r_t A_t = 3.0, \text{clip}(1.5, 0.8, 1.2) A_t = 2.4$

즉 r_t 가 1.2를 넘어도 L^{clip} 은 평평


$\epsilon = 0.2, A_t = -2, r_t = 0.5$
 $r_t A_t = -1.0, \text{clip}(0.5, 0.8, 1.2) A_t = -1.6$

즉 r_t 가 0.8보다 작아져도 L^{clip} 은 더 이상 좋아지지 않음 오히려 감소

Method

- Multiple epochs of minibatch updates


- 기존 정책 경사는 같은 데이터를 여러 번 쓰면 정책이 크게 바뀔수 있어서 위험했으나 PPO는 클리핑으로 그 변화를 억제하기 때문에 여러 번 재사용하는게 가능해짐 따라서 표본 효율성 향상



Method

- Generalized Advantage Estimation
 - 안정적인 $\hat{A}_t$ 추정하기 위해
 - 현재 행동이 예상보다 얼마나 좋았는지 여러 timestep의 정보를 섞어 계산
- Value Function Loss
 - 마찬가지로 더욱 정확한 $\hat{A}_t$ 추정하기 위해
 - 제곱오차를 이용해서 Value Function이 더욱 정확하도록 학습
- Entropy Bonus
 - Policy가 너무 빨리 변하는 것을 막기 위해
 - 다양한 행동을 하면 엔트로피가 높고 한행동만 고르면 엔트로피가 낮으므로 다양성을 추구

Method



Experiment

1. 정말 클리핑이 다른 surrogate objective보다 나은지
2. PPO가 기존 강화학습 알고리즘 보다 실제 성능이 좋은지
3. 복잡한 고차원 연속 제어에서도 잘 되는지
4. 연속 제어 뿐 아니라 Atari 같은 이산 행동 문제에도 잘 되는지

Dataset

- 7개의 MuJoCO simulated robotics task
- 각 환경에서 1,000,000 timestep 동안 학습했고 각 알고리즘 설정마다 3개의 랜덤 시드 사용
- 7개 환경X 3개의 시드=21개의 실행을 하나의 정규화 점수로 변환(환경마다 보상척도가 다르기 때문)


Experiment1

1. No clipping or penalty
2. Clipping
3. KL penalty

algorithm	avg. normalized score
No clipping or penalty	-0.39
Clipping, $\epsilon = 0.1$	0.76
Clipping, $\epsilon = 0.2$	0.82
Clipping, $\epsilon = 0.3$	0.70
Adaptive KL $d_{\text{targ}} = 0.003$	0.68
Adaptive KL $d_{\text{targ}} = 0.01$	0.74
Adaptive KL $d_{\text{targ}} = 0.03$	0.71
Fixed KL, $\beta = 0.3$	0.62
Fixed KL, $\beta = 1.$	0.71
Fixed KL, $\beta = 3.$	0.72
Fixed KL, $\beta = 10.$	0.69


Experiment2

1. TRPO(신뢰영역 정책 최적화)
2. Vanilla Policy Gradient(기본 정책 경사)
3. A2C(Advantage Actor-Critic)
4. A2C+Trust Region
5. CEM(Cross-Entropy Method)



Experiment3


- 성능 시연-3D 휴머노이드가 복잡한 행동(앞으로 달리기, 넘어졌다가 일어나기 등)을 배우는 상황에서도 실제로 학습된다는 것을 보여줌



Experiment4

- 49개의 Atari game 비교

1. PPO
2. A2C
3. ACER




	A2C	ACER	PPO	Tie
(1) avg. episode reward over all of training	1	18	30	0
(2) avg. episode reward over last 100 episodes	1	28	19	1

Experiment4

- 49개의 Atari game 비교

1. PPO
2. A2C
3. ACER



	A2C	ACER	PPO	Tie
(1) avg. episode reward over all of training	1	18	30	0
(2) avg. episode reward over last 100 episodes	1	28	19	1

Discussion & Limitation

- PPO는 클리핑 대리 목적함수를 이용해 정책 업데이트가 지나치게 커지는 것을 억제하면서 같은 데이터를 여러 에폭동안 학습할 수 있게 했음
- 기존 TRPO 방법보다 훨씬 단순하면서도 그에 대등한 성능을 보여 표본 효율성, 단순성, 실제 계산시간의 이득을 가져옴
- 클리핑이 다른 패널티보다 항상 우월하다는 이론적 증명 없이 실험을 통해 보였으며 성능 우위의 주장은 주로 벤치마크 실험을 통한 경험적 근거
- 클리핑 파라미터, 학습률 에폭수 등 하이퍼파라미터의 영향을 받으므로 저자들은 하이퍼파라미터 세팅을 공개

이후 연구

- 2019~2020: PPO 클리핑이 정말 proximal한가
- 2020: PPO 성능이 정말 클리핑 때문인가 아니면 구현 세부사항 때문인가
- 2024: PPO는 실험적으로 먼저 성공했고 이론적으로 성질을 분석

-
- 2022: PPO를 인간 피드백 기반 강화학습(RLHF)에 정책 미세조정으로 사용(GPT-3)
 - 2023~2024: 그런데 PPO 기반 RLHF는 너무 복잡하여 LLM 분야에 맞는 DPO와 GRPO가 등장
 - 2024~현재: 강화학습을 이용해 추론을 강화하는 연구(DeepSeek-R1)

Thank you for
your attention