

PAPER

Deep double descent: where bigger models and more data hurt^{*}

To cite this article: Preetum Nakkiran *et al* *J. Stat. Mech.* (2021) 124003

View the [article online](#) for updates and enhancements.

You may also like

- [Generalized hydrodynamics in the one-dimensional Bose gas: theory and experiments](#)
Isabelle Bouchoule and Jérôme Dubail
- [Reconstruction of pairwise interactions using energy-based models](#)
Christoph Feinauer and Carlo Lucibello
- [Correlation functions and transport coefficients in generalised hydrodynamics](#)
Jacopo De Nardis, Benjamin Doyon, Marko Medenjak et al.

December 29, 2021

오서영

Abstract

- 최근 딥러닝에서는 모델 크기가 증가하면 처음에는 성능이 악화되다가 후에 개선되는 이중 하강(double descent) 현상이 나타남을 증명
- 이중 하강 현상은 모델의 크기 뿐만 아니라 훈련 epoch 수에 따라서도 발생하는 것을 보여줌.
- 또한, 새로운 복잡도 측정 지표인 '유효 모델 복잡도(effective model complexity; EMC)를 정의
- 이를 통해 훈련 샘플 수를 증가시키는 것이 테스트 성능의 저하로 이어지는 것을 확인

Introduction

- 통념


- 모델 복잡도 : 일정 수준을 넘으면 과적합으로 인해 test error 증가
- 훈련시간 : 훈련시간이 길어지면 테스트 성능이 저하
- 데이터 : 학습데이터가 많을수록 테스트 성능이 향상

- 문제 제기

- 모델 복잡도가 작은 구간에서는 test error가 고전적인 U자형 곡선
- 모델이 훈련자료를 완전히 학습하는 구간에서는 test error가 크게 증가
- 모델 복잡도가 그 이상으로 커진다면 test error가 다시 감소하는 double descent 현상이 발견
- 기존의 통념은 일부 구간에서만 성립하고, 전체 학습 양상을 설명하기에는 부족함.

Contribution

- Double descent(이중 하강)현상이 다양한 아키텍처와 최적화 방법에서 발생하는 현상임을 실험적으로 확인.
- 훈련 절차의 EMC를 training error가 거의 0에 가까워질 수 있는 최대 샘플 수로 정의함



Hypothesis

- 훈련 샘플 집합 $S = \{x_n, y_n\}_{n=1}^N$

1. EMC

- 분포 D 와 학습 절차 T , 파라미터 $\varepsilon > 0$ 일때

$$EMC_{D,\varepsilon}(T) := \max\{n | E_{S \sim D^n}[Error_S(T(S))] \leq \varepsilon\}$$


• 가설

- 모든 데이터 분포 D , NN기반 학습 절차 T , 작은 $\varepsilon > 0$ 에 대해 n 개의 샘플 기반 라벨 예측 작업을 할 경우
 1. Under-parameterized regime : EMC가 n 보다 충분히 작고, T 의 유효 복잡성이 증가하면 테스트 오류가 감소함.
 2. Over-parameterized regime : EMC가 n 보다 충분히 작고, T 의 유효 복잡성이 증가하면 테스트 오류가 감소함.
 3. Critically parameterized regime : EMC와 n 이 유사하면 교란이 발생하여 T 의 유효 복잡성이 증가할 경우 테스트 오류가 감소하거나 증가함.

Dataset & Model



- Dataset
 - CIFAR-10 & CIFAR-100
 - IWSLT'14 German-to-English
- Model
 - ResNet18 : width를 변화시켜 복잡도 조절
 - 5-layer CNN : width 변화
 - Transformer : embedding dimension 변화
 - SGD, Adam : 최적화 방법에 따른 변화 확인

Model-wise double descent



- **모델 크기 증가에 따른 test error 실험**
- 모델 크기 증가하면 test error 감소하다가 임계 영역 부근에서 증가하다 다시 감소
- 모델이 클 수록 test error 감소
- Label noise가 증가할수록 test error의 peak가 뚜렷해짐
- Figure 5~8은 정규화와 최적화방법에 따른 변화를 본 그림으로, 해당 실험들에서도 이중하강현상이 관찰됨




Epoch-wise double descent



- **Epoch수에 따른 test error 실험**

- 모델의 크기를 고정하고 훈련시간(epoch)을 증가시키면 EMC가 증가
- 충분히 큰 모델에서는 test error가 이중 하강 현상을 보임
- 중간 크기의 모델에서는 전통적인 U자형 변화가 나타나 early stop이 효과적인 것을 알 수 있음
- 작은 모델에서는 보간 임계점에 도달하지 못해 test error가 지속적으로 감소함

Sample-wise Non-monotonicity



- 데이터 수에 따른 test error 실험
- Sample 수가 증가하면 전반적인 test error 감소
- 또한, 보간 임계점과 test error의 peak는 훈련표본수가 증가하면, 더 큰 모델 쪽으로 이동
- 특정 구간에서는 훈련표본 수가 증가할수록 test loss가 증가하는 것도 확인

Conclusion

- 일반화된 이중 하강 가설(double descent)을 제시함
 - 해당 가설을 통해 모델과 훈련 절차에서 EMC가 훈련 샘플 수와 유사할 때 비정상적인 동작을 확인
 - 최신 딥러닝 환경에서 해당 가설의 현상을 설명하고, 더 큰 모델에서의 성능 저하 영역을 규명함
 - 기존에 제안된 적 없는 epoch별 이중 하강 현상도 제시하였으며, train data의 수가 증가할 수록 test 성능이 저하되는 현상도 확인
- Early stop
 - 이중 하강 현상은 조기 종료 사용시 발생하지 않기때문에, 모델의 train error가 0에 도달하지 않는다면, 이중 하강 현상이 발생하지 않음.
 - 최적의 early stop 사용시에 데이터 양이 많아도 문제가 되는 상황은 관찰하지 못하였지만, 이유를 파악하지 못해 향후 연구로 남김.

Conclusion

- Label noise
 - Label noise가 있는 환경에서 double descent 현상이 가장 강하게 관찰됨
 - 이를 추가해서 분포를 더 어렵게 만드는 모델 설정 오류가 발생해 double descent 현상이 강해짐
- Other notions of model complexity
 - 고전적인 복잡성(Rademacher complexity 등)과 달리 EMC는 데이터 분포의 실제 레이블과 모델 아키텍처, 훈련절차에 의존함.
 - 고전적인 복잡성 개념은 double descent peak의 위치를 특정하기에 충분하지 않음