FixMatch: Consistency와 Confidence의 단순한 결합

FixMatch

Simplifying Semi-Supervised Learning with Consistency and Confidence

---

Consistency regularization + Confidence-based pseudo-labeling

Sohn et al. · NeurIPS **2020** · Google Research

ABSTRACT

초록: 단순한 규칙으로 높은 분류 정확도를 얻었다

CIFAR-10 · 250 labels

94.93%

Test accuracy

CIFAR-10 · 40 labels

88.61%

Test accuracy

핵심 작동 메커니즘

- weak image에서 pseudo-label을 생성

↓

- 최대 클래스 확률이 threshold 이상일 때만 채택

↓

- strong image가 pseudo-label과 일치하도록 학습

문제: 좋은 모델을 위해 필요한 레이블 비용이 크다

Labeled data

x, y

사람이 제공한 정답과 함께 학습하는 비교적 소량의 자료

Unlabeled data

u

사람의 정답이 없는 다량의 이미지. 직접적인 분류 손실을 사용할 수 없음

Semi-Supervised Learning(SSL)의 질문:
정답 없는 이미지에서도 학습 신호를 만들 수 있는가?

PROBLEM SETUP

학습 입력은 labeled batch와 unlabeled batch로 나뉜다

Labeled batch

$$B = 64$$

$X = \{(x_b, p_b)\}$
이미지 + one-hot label

Unlabeled batch

$$\mu B = 448$$

$U = \{u_b\}$, μ 는 비율(Scalar)이고 B는 Labeled 배치 크기, Unlabeled 배치 크기는 두 값을 곱한 형태인 μB (즉, $7 \times 64 = 448$)
정답 없는 이미지

- Labeled: $X = \{(x_b, p_b)\}$, $b = 1, \cdots, B$
- Unlabeled: $U = \{u_b\}$, $b = 1, \cdots, \mu B$
- $p_m(y|x)$: 모델의 클래스 확률분포 · μ: 두 배치 크기 비율

기본 설정인 B=64, μ =7을 적용하면, 매 iteration마다 라벨 이미지 64장과 라벨 없는 이미지 448장(7×64)을 한꺼번에 모델에 입력하여 학습을 진행

FixMatch의 첫 번째 축: Consistency regularization

Consistency regularization: 동일한 이미지에 서로 다른 변형(Augmentation)을 가하더라도, "모델의 예측 결과는 일관되어야 한다"는 원칙

같은 이미지에 대한 두 stochastic prediction을 가까이

$$\sum_{b=1}^{\mu B} \| p_m(y \mid \alpha(u_b)) - p_m(y \mid \alpha(u_b)) \|_2^2$$

고전 모델에서 사용하던 L2 거리(MSE) 기반 일관성 손실 함수

α: 무작위성(Stochasticity)을 가지는 증강 함수

prediction A = [0.8, 0.2]

prediction B = [0.6, 0.4]

설명용 계산

Eq. (1)은 선행 consistency loss 예시이며 FixMatch의 최종 loss가 아님

FixMatch의 두 번째 축 Pseudo-labeling

Pseudo-labeling : 확신 있는 예측만 임시 정답으로 쓴다

$$\frac{1}{\mu B}\sum_{b=1}^{\mu B}\mathbb{1}(\max(q_b)\geq\tau)\,H(\hat{q}_b,q_b)$$

"Confidence"

- $q_b = p_m(y|u_b)$: 모델이 추정한 클래스 확률
- q argmax q_b one-hot label
- $\mathbb{I}(\max(q_b) \geq \tau)$: confidence threshold 통과 여부

  - 모델의 확신도(Confidence)가 **임계값 τ(예: 0.95)를 넘을 때만 임시 정답으로 채택**하여 잘못된 라벨로 인한 노이즈 전파 방지
  - **Threshold 미달 시 indicator = 0** → 해당 샘플 loss 기여 = 0

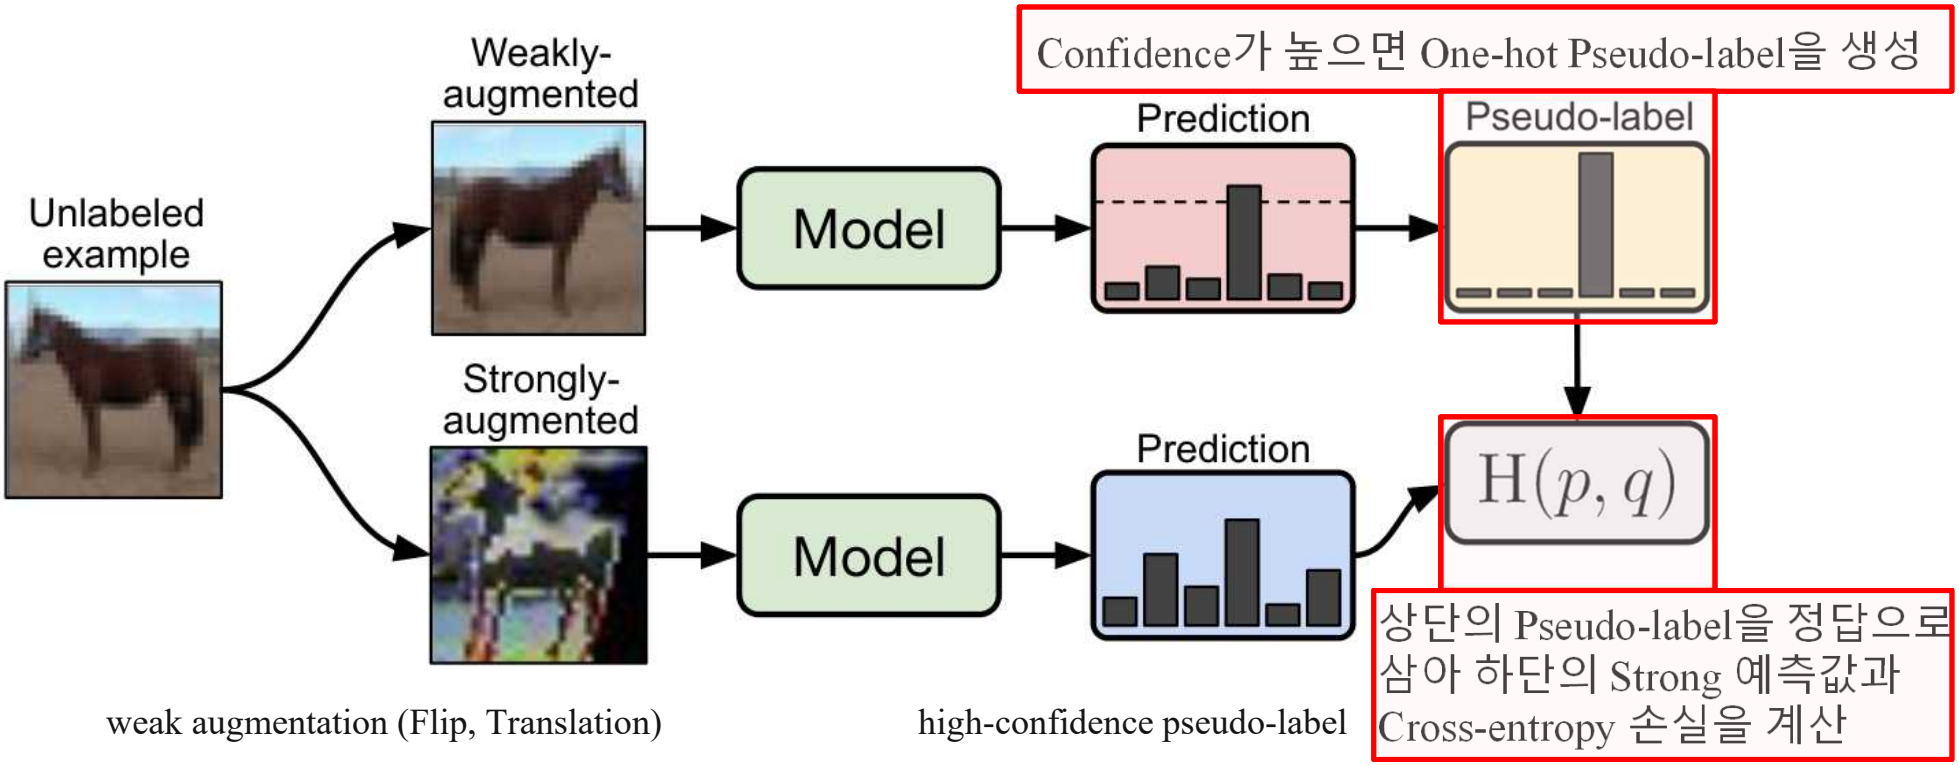
Sohn et al. (2020), p. 3, Eq. (2)

Table1. FixMatch는 기존 SSL의 핵심만 남긴 조합

Algorithm	Artificial label augmentation	Prediction augmentation	Artificial label post-processing	Notes
TS / Π-Model	Weak	Weak	None	
Temporal Ensembling	Weak	Weak	None	Uses model from earlier in training
Mean Teacher	Weak	Weak	None	Uses an EMA of parameters
Virtual Adversarial Training	None	Adversarial	None	
UDA	Weak	Strong	Sharpening	Ignores low-confidence artificial labels
MixMatch	Weak	Weak	Sharpening	Averages multiple artificial labels
ReMixMatch	Weak	Strong	Sharpening	Sums losses for multiple predictions
FixMatch	Weak	Strong	Pseudo-labeling	

- **Weak**: 수평 뒤집기(Flip), 이동(Translation) 등 원본의 형태를 크게 훼손하지 않는 단순 증강.
- **Strong**: Cutout, RandAugment, CTAugment 등 이미지의 색상이나 구조를 크게 변형시키는 강한 증강.
- **Adversarial**: 모델이 잘못 예측하도록 노이즈를 미분하여 주입하는 적대적 적대 노이즈.
- **Sharpening**: 소프트맥스 확률 분포의 온도(Temperature)를 낮추어 특정 클래스의 확률을 뾰족하게 만드는 기법 (엔트로피 최소화 목적). → **복잡**
- **Pseudo-labeling**: 확신도(Confidence)가 임계값(τ)을 넘는 경우만 선택하여 가장 높은 확률을 가지는 클래스를 One-hot vector(Hard label)로 변환하는 기법.

Figure 1 하나의 이미지를 weak와 strong 경로로 나눈다



- weak augmentation (Flip, Translation) high-confidence pseudo-label
- 하단: strong augmentation (Cutout, RandAugment, CTAugment) → 예측
- cross-entropy

Confidence gate는 손실에 참여할 샘플을 결정한다 (수치 예시)

설명용 예시 · 3-class classification · τ = 0.95

	0.97 ≥ 0.95	채택: pseudo-label [0,1,0]
[0.13, 0.82, 0.05]	0.82 < 0.95	제외: loss weight = 0

이 숫자는 논문 관측값이 아닌 개념 설명용 예시

Weak와 Strong augmentation은 서로 다른 역할을 한다

WEAK augmentation

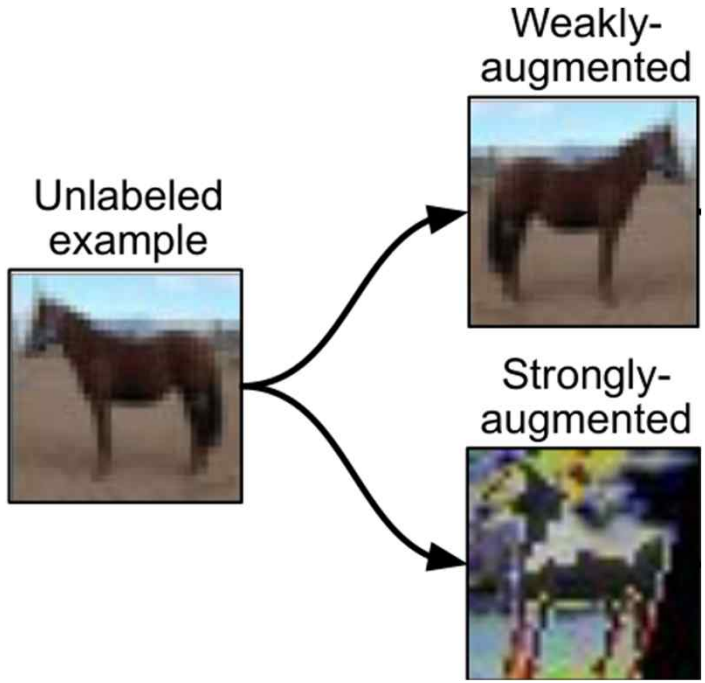
$$\alpha(u)$$

Flip + 작은 이동
Pseudo-label 생성용

STRONG augmentation

$$A(u)$$

RandAugment / CTAugment + Cutout



- Weak: horizontal flip(50%, SVHN 제외) + shift(최대 12.5%)
- Strong RandAugment CTAugment Cutout
- Weak는 pseudo-label의 안정성, strong은 변형에 대한 견고성을 담당

Eq. labeled data는 표준 cross-entropy로 학습한다

사람이 부여한 label p_b가 정답인 부분

지도손실
(정답이 있는 문제로 공부) $\ell_s = \frac{1}{B} \sum_{b=1}^{B} H(p_b, p_m(y \mid \alpha(x_b)))$

소량의 라벨이 있는 데이터

Weak 변형

- B: 정답이 있는 문제의 개수 (배치 크기)
- $\alpha(x_b)$: 살짝 뒤집거나 움직인 사진 ($Weak\ Augmentation$)
- $H(\cdot,\cdot)$: 채점표 ($Cross-Entropy$ 손실함수, 정답과 예측이 다르면 점수가 깎임)

Cross-entropy example

true class prob. 0.8 → $-\ln(0.8) = 0.223$

Cross-entropy example

true class prob. 0.2 → $-\ln(0.2) = 1.609$

Eq. (4): confident weak label로 strong output을 지도한다

unlabeled loss에 strong prediction과 confidence mask를 함께 사용

비지도 손실 (정답이 없는 문제로 공부)

$$\ell_u = \frac{1}{\mu B} \sum_{b=1}^{\mu B} \mathbb{1}(\max(q_b) \geq \tau) H(\hat{q}_b, p_m(y \mid \mathcal{A}(u_b)))$$

Output: 0 or 1

Strong 변형

- μB: 정답 없는 문제의 개수 (μ배 만큼 많이 가져옴)
- $\mathbb{I}(\max(q_b) \geq \tau)$: 스위치(지시함수). AI의 확신도($\max(q_b)$)가 0.95(τ)를 넘으면 1(채점함), 안 넘으면 0(버림).
- $\hat{q}_b$: 약하게 증강된 이미지에서 얻은 Pseudo − Label, $\text{argmax}(q_b) \rightarrow$ One-hot 벡터(Hard Label) 형태
- $p_m(y \mid \mathcal{A}(u_b))$: 훼손된 사진을 보고 AI가 예측한 답

① Weak target

$$q_b = p_m(y|\alpha(\mu_b))$$

② Confidence gate

$$\mathbb{I}(\max(q_b) \geq \tau)$$

③ Strong prediction

$$p_m(y \mid \mathcal{A}(u_b))$$

전체 목적함수는 두 cross-entropy의 단순한 합이다

두 손실의 합을 최소화하도록 한 번에 업데이트

$$\ell = \ell_s + \lambda_u \ell_u \qquad (\lambda_u = 1)$$

Supervised signal
사람이 붙인 실제 label이 모델을 지도

Unsupervised signal
threshold를 통과한 pseudo-label로 학습

※ 준지도학습(Semi-Supervised Learning) 연구에서는 지도학습 손실ℓ_s)과 비지도학습 손실ℓ_u)의 균형을 맞추기 위해 비지도 손실 앞에 가중치 하이퍼파라미터 λ_u를 두는 것이 표준적인 관례

- **"튜닝이 필요 없다"는 핵심 이점 강조 (Ablation / Key Message)**

기존 SSL 모델들(MixMatch, ReMixMatch, UDA 등)은 성능을 극대화하기 위해 데이터셋이나 실험 조건마다 λ_u 값(예: 0.1, 1, 10, 또는 학습 진행에 따른 Warm-up 스케줄링)을 세밀하게 튜닝해야 했습니다.
FixMatch 저자들은 "우리가 제안한 구조는 λ_u 를 복잡하게 튜닝할 필요 없이 그냥 1로 고정하더라도 $\lambda_u = 1$) 모든 벤치마크에서 SOTA 성능이 나온다"는 점을 강력하게 어필하기 위해 일부러 **$\lambda_u = 1$ 임을 수식 옆에 강조**

ALGORITHM · SIMPLIFIED FROM §2.2

학습 절차: 예측, 필터링, 손실 결합, 파라미터 갱신

한 학습 단계(Iteration)의 입력: X, U, 모델 f, confidence threshold τ

Labeled branch

$\text{weak(x)} \rightarrow \text{f} \rightarrow \ell_s$

+

Unlabeled branch

$\text{weak(u)} \rightarrow \hat{q} + [\textbf{mask} = \mathbb{I}(\max(q_b) \geq \tau)]$

$\text{strong(u)} \rightarrow \text{f} \rightarrow \ell_u$

$\ell_s + \lambda_u \cdot \ell_u \rightarrow$ **parameter update** (이 두 손실을 더해 역전파를 수행하고 모델 파라미터 f를 갱신)

저자 본문 §§2.2에 근거한 발표용 재구성 절차 · Supplementary Algorithm 1 원문 아님

실험은 네 가지 소형 벤치마크와 ImageNet을 사용했다

Dataset	Labeled splits	Model
CIFAR-10	40 / 250 / 4000	WRN-28-2
CIFAR-100		WRN-28-8
SVHN	40 / 250 / 1000	WRN-28-2
STL-10	1000	WRN-37-2

※ WRN-28-2: Wide ResNet(Wide Residual Network) 의 세부 구조. 28: 신경망 깊이(레이어 개수), 2: 채널 너비

Common setting (except ImageNet)

$$B = 64 \quad \mu = 7 \quad \tau = 0.95 \quad \lambda_u = 1 \quad \eta = 0.03 \quad \beta = 0.9 \quad K = 2^{20}$$

RESULTS · TABLE 2A

Table 2: CIFAR-10은 적은 레이블에서도 낮은 오류율

CIFAR-10 · Error rate (%) · 5 labeled-data folds

Method	40 labels	250 labels
UDA	29.05 ± 5.93	8.82 ± 1.08
ReMixMatch	19.10 ± 9.64	5.44 ± 0.05
FixMatch (RA)	**13.81 ± 3.37**	**5.07 ± 0.65**
FixMatch (CTA)	**11.39 ± 3.35**	**5.07 ± 0.33**

RandAugment(RA), CTAugment(CTA) 등 이미지의 색상이나 구조를 크게 변형시키는 강한 증강.

CIFAR-100 · 400 labels · Error rate (%)

ReMixMatch	FixMatch (RA)	FixMatch (CTA)
44.28 ± 2.06	48.85 ± 1.75	49.95 ± 3.01

FixMatch+DA error ?

Sohn et al. (2020), p. 6, Table 2 (CIFAR-10/100 열 발췌)

Table 2: SVHN과 STL-10에서 성능은 조건별로 달라진다

SVHN / STL-10 · Error rate (%) · 5 folds

Method	SVHN 40	SVHN 250	STL-10 1000
ReMixMatch	**3.34 ± 0.20**	2.92 ± 0.48	**5.23 ± 0.45**
FixMatch (RA)	H	**2.48 ± 0.38**	7.98 ± 1.50
FixMatch (CTA)	H	**2.64 ± 0.64**	**5.17 ± 0.63**

Augmentation 설정에 따른 변동성이 커짐

읽는 법: 모든 수치는 분류 오류율 → 작을수록 좋음

SVHN 40 labels augmentation

ImageNet: 10% labeled 설정에서도 적용 가능성을 보였다

ImageNet / top-1 error

28.54 ± 0.52%

labeled ResNet-50

ImageNet / top-5 error

10.87 ± 0.28%

10% labeled · RandAugment

UDA top-1 error 2.68 percentage points S4L

간결한 학습 원리가 대규모 분류 문제에서도 작동한다는 경험적 근거를 제시

Figure 2: 클래스당 한 장에서는 대표 이미지의 품질이 중요하다

CIFAR-10 · one label per class · Figure 2 원본 10장



Random sets

64.28%

accuracy 중앙값

최종 정확도 범위가 48.58%에서 85.32%

어떤 사진 한 장을 선택했는지에 따라 성능이 크게 달라진다는 뜻

Representative sets

78%

accuracy

Outlier sets

10%

학습 실패: accuracy

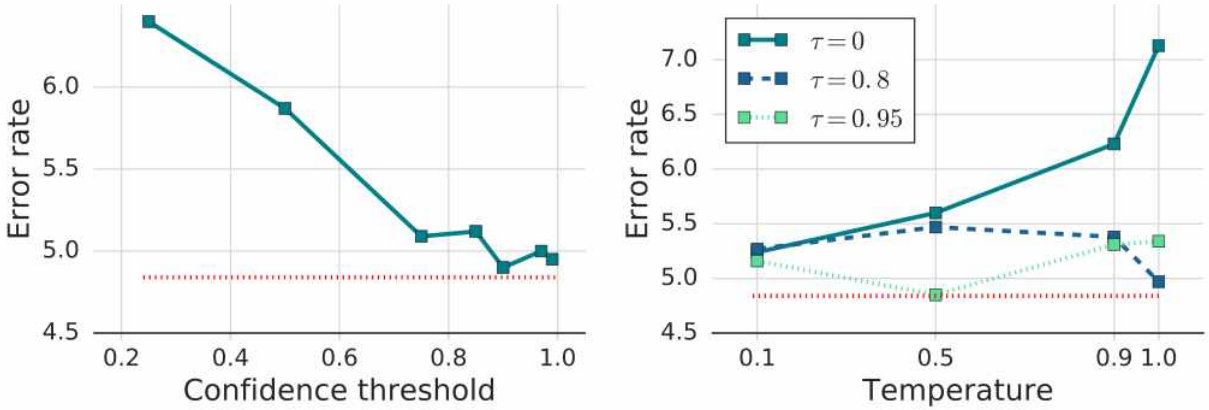
대표성에 따라 이미지를 나눠 실험

labeled data

label

Figure 3: confidence threshold가 pseudo-label 품질을 조절한다

원문 Fig. 3 · CIFAR-10 단일 250−label split · 붉은 점선은 기본 성능 기준



(a)

threshold를 높일수록 오류율이 상당히 감소하고, 0.95 주변에서 좋은 결과

(b)

확률분포를 날카롭게 만드는 sharpening의 temperature를 바꾸며 측정한 결과

→ temperature라는 추가 hyperparameter를 도입하지 않고 hard pseudo-label을 사용하는 선택을 뒷받침

Fig. 3a · T

threshold

Fig. 3b · T

threshold가 있을 때 sharpening 추가 이점 제한

Table 3: strong augmentation과 Cutout의 조합이 필요했다

Ablation	Error
FixMatch	4.84
Only Cutout	6.15
No Cutout	6.15

Ablation (CIFAR-10 / 250 labels)

기본 FixMatch : 4.84%

Only Cutout : 6.15%

No Cutout : 6.15%

strong augmentation 설계가 중요한지를 보여주는 Table 3

Strong만으로 target을 만들면 학습 초기에 발산

split Table 2 fold

결론: 단순한 loss, 그러나 데이터와 학습 설정은 중요하다

Contribution

Confidence-based hard pseudo-label
+ weak-to-strong consistency
+ 간단한 cross-entropy objective

Interpretation & limits

극소량 레이블의 대표성 문제(e.g., 클래스 당 한 장처럼 극단적으로 레이블이 적은 Fig 2.)
CIFAR-100 기본 모델의 예외
optimizer · weight decay · augmentation 민감도

Take-home message: 단순한 학습 목표의 성공은 적절한 data/augmentation 조건과 함께 해석해야 한다.

FOLLOW-UP RESEARCH · 2021–2026

FixMatch 이후 SSL은 네 방향으로 확장되었다

Pseudo-label 신뢰도 개선 · 특징 표현 활용 · Foundation Model 결합 · Dense prediction

01 임계값의 적응과 완화

FlexMatch · NeurIPS 2021

클래스별 학습 상태에 따라 threshold 조절

SoftMatch · ICLR 2023

confidence 기반 truncated Gaussian 가중치

02 Pseudo-label + 표현 공간

CoMatch · ICCV 2021

pseudo-label과 graph contrastive 학습 결합

SimMatch · CVPR 2022

semantic / instance similarity 동시 정합

03 Foundation Model 활용

LADaS · CVPR 2025

언어 지식으로 pseudo-label 편향·노이즈 완화

CLIP / DINOv2

사전학습 prior / 특징; 별도 SSL 알고리즘은 아님

04 분류에서 Dense Prediction으로

Unbiased Teacher · ICLR 2021

teacher–student 기반 object detection

UniMatch · CVPR 2023

weak-to-strong consistency 기반 segmentation

핵심 | 고정된 pseudo-label 선택 규칙을 개선하고, 학습 정보와 적용 과제를 확장

Sources: Zhang et al. (2021); Li et al. (2021); Liu et al. (2021); Zheng et al. (2022, 2025); Chen et al. (2023); Yang et al. (2023); Oquab et al. (2024)