A Bayesian nonparametric meta-analysis model for estimating the reference interval

Wenhao Cao et al. 2024, Statistics in Medicine

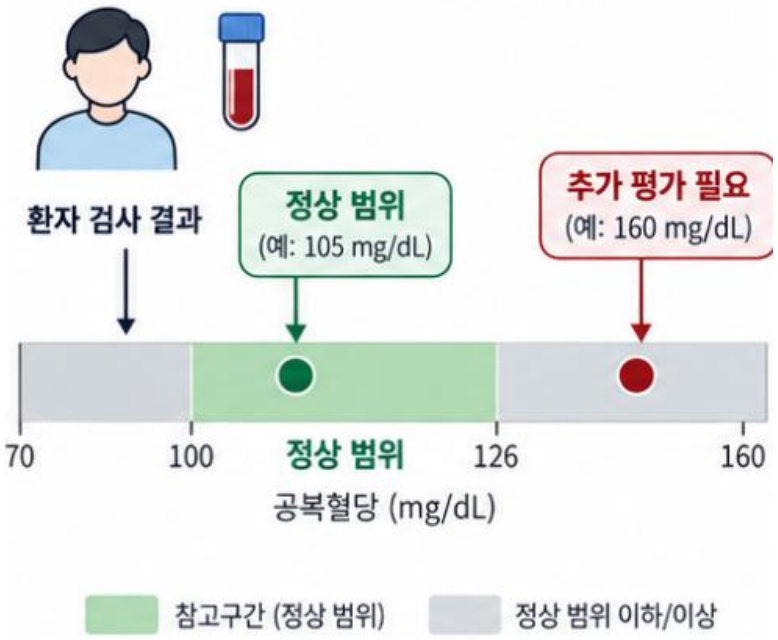
Introduction

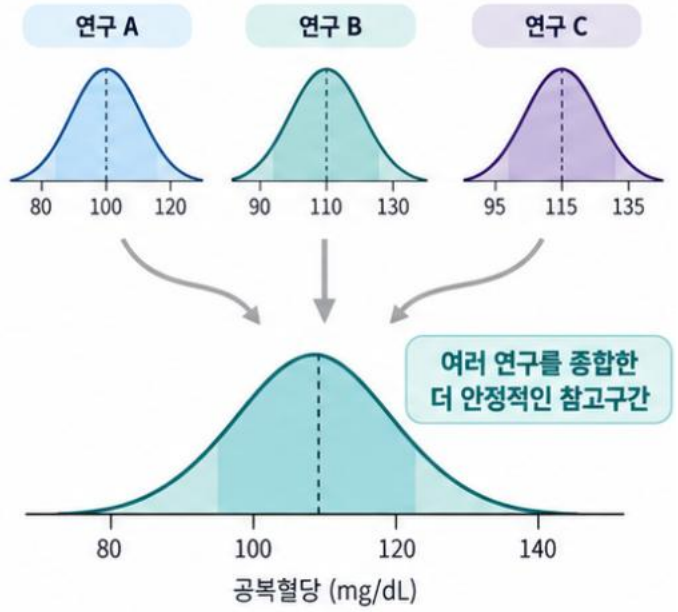
- 여러 연구의 결과를 통합함으로써 결합된 모집단에 기반한 구간을 제공할 수 있는 메타분석이 존재

- 그러나 기존 방법은 일반적으로 연구간 평균이 정규분포를 따른다는 가정, 연구 내 분산이 동일하다는 가정이 있음

- 본 연구에서는 기준 구간 추정을 위한 랜덤효과메타분석을 확장하기 위한 Bayesian nonparametric 모델을 제안

Background





- 혈당, 혈압 등 의학에서는 건강한 사람들의 정상 범위를 정하는 경우가 있음

- 이 때 하나의 연구에서 나온 구간을 사용할 경우 불안정할 수 있어 여러 연구를 종합한 구간을 사용해야

Random-effects meta-analysis

$$\underbrace{\theta_i}_{\text{연구 간 평균}} \sim N(\mu, \tau^2), \qquad \underbrace{\bar{Y}_i}_{\text{연구 내 평균}} | \theta_i \sim N\left(\theta_i, \frac{\sigma^2}{n_i}\right)$$

- 연구 간 평균이 다르다고 놓는 것이 랜덤효과 메타분석 그러나 그것이 정규분포를 따른다고 가정한다는 제한이 존재(θ_i)
- 또한 연구내 분산이 같다는 가정도 존재(σ^2)
- 본 연구는 이 두가지 가정을 완화하는데서 출발

Model comparison

$$\bar{Y}_i|\theta_i \sim N\left(\theta_i, \frac{\sigma^2}{n_i}\right), \qquad \theta_i \sim N(\mu, \tau^2)$$

parametric random-effect model

$$\bar{Y}_i|\theta_i, \sigma^2 \sim N\left(\theta_i, \frac{\sigma^2}{n_i}\right), \qquad \theta_i|G \sim G, \quad G \sim DP(\alpha, G_0)$$

Section 2.1-NP(등분산)

$$\bar{Y}_i|\theta_i, \sigma_i^2 \sim N\left(\theta_i, \frac{\sigma_i^2}{n_i}\right), \qquad \theta_i|G \sim G, \quad G \sim DP(\alpha, G_0), \quad \sigma_i|G_\sigma \sim G_\sigma, \quad G_\sigma \sim DP(\alpha_\sigma, G_{0\sigma})$$

Section 2.2-NP2

NP

$$\bar{Y}_i|\theta_i, \sigma^2 \sim N\left(\theta_i, \frac{\sigma^2}{n_i}\right), \qquad \theta_i|G \sim G \qquad G \sim DP(\alpha, G_0)$$

여기서

$$G = \sum_{i=1}^{\infty} \pi_i \delta_{\gamma_i}, \qquad \gamma_i \sim G_0$$

각 가중치 π_i는

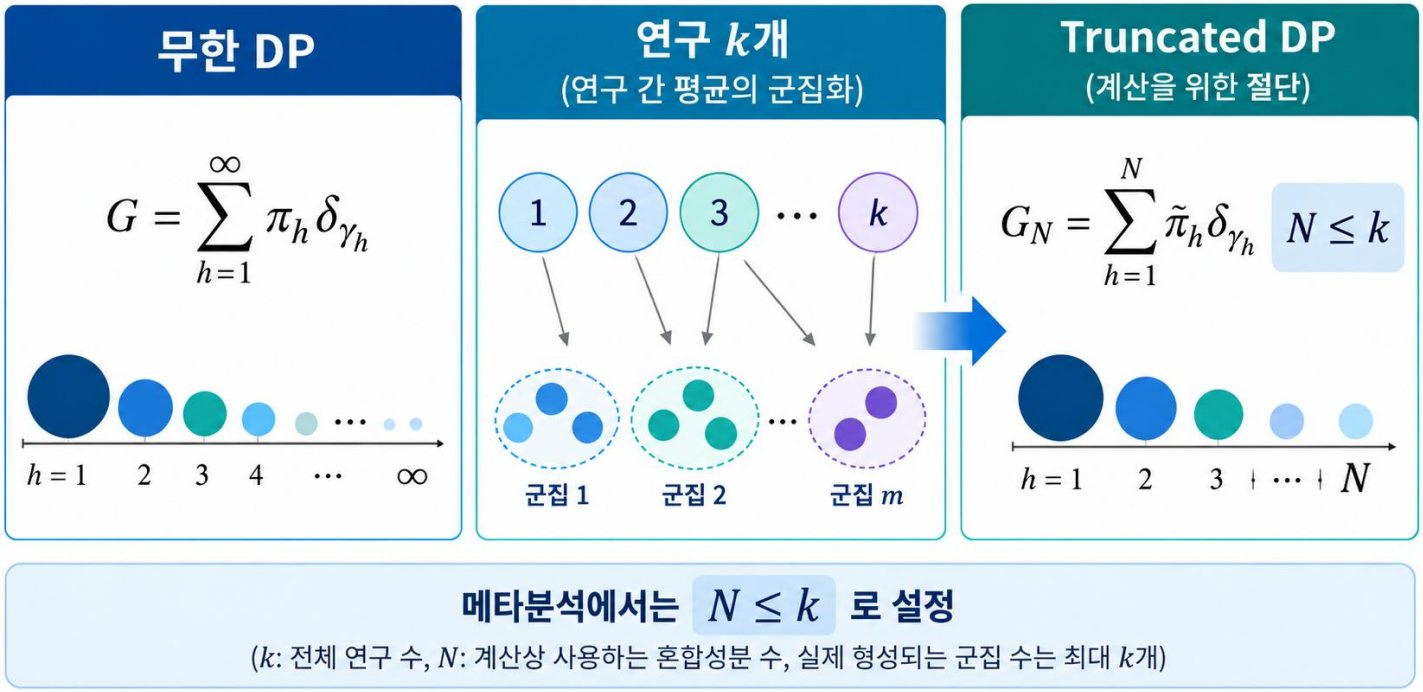
$$\pi_i = V_i \prod_{\ell<i} (1 - V_\ell), \qquad V_i \sim Beta(1, \alpha)$$

γ_i: 연구 평균이 가질 수 있는 잠재적인 값
π_i: 그 값이 선택될 확률
$\delta_{\gamma i}$: 확률질량을 정확히 γ_i에 두는 점질량 분포

Stick-breaking

$$G = \sum_{i=1}^{\infty} \pi_i \delta_{\gamma_i}, \qquad \gamma_i \sim G_0 \quad \Rightarrow \quad G_N = \sum_{h=1N} \tilde{\pi}_h \delta_{\gamma_h}, \qquad N \leq K$$

- DP는 이론적으로 무한개의 집단을 설정할 수 있으나 계산상 필요한 적절한 N개를 선택



Conditional prior predictive distribution

$$\theta_i|\alpha,\theta_1,\cdots,\theta_{i-1} \propto \frac{\alpha}{i-1+\alpha}\phi_0(\theta_i) + \frac{1}{i-1+\alpha}\sum_{j=1}^{i-1}\delta(\theta_j)$$

ϕ_0 : G_0의 확률밀도함수
$\delta(s)$: s에 확률질량이 집중된 Dirac 분포

- G_0는 미지의 분포 G의 사전적 중심을 지정하며 정규 기저분포를 사용하여 조건부 켤레성을 활용

base distribution G_0는

$\boxed{G_0 = N(\mu, \tau^2)}$

$\mu \Leftarrow$ 정규 사전분포
$\tau^2 \Leftarrow$역감마 사전분포 but

조건부 켤레 사전분포 구성

τ^2에 대한 정보가 부족하면 문제가 되므로

$\tau \sim U(0,10)$

Conditional posterior distribution

$$p(\theta_i|y, s^2, \theta_{-i}, \sigma^2, \tau^2)$$

$$\propto \sum_{j \neq i} \phi\left(y_i|\theta_j, \frac{\sigma^2}{n_i}\right) \cdot \delta_{\theta_j} + \left\{\alpha \int \phi\left(y_i|\theta_i, \frac{\sigma^2}{n_i}\right) \phi(\theta_i|\mu, \tau^2) d\theta_i\right\}$$

$$\times \phi\left(y_i|\theta_i, \frac{\sigma^2}{n_i}\right) \phi(\theta_i|\mu, \tau^2)$$

다른 파라미터들도 마찬가지로 조건부 사후추론 수행

$$p(\sigma^2|y, s^2, \theta, \mu, \tau^2, \alpha) \qquad p(\mu|y, s^2, \theta, \sigma^2, \tau^2, \alpha)$$

$$p(\tau^2|y, s^2, \theta, \sigma^2, \mu, \alpha) \qquad p(\alpha|y, s^2, \theta, \sigma^2, \mu, \tau^2)$$



조건부 사후분포를 이용해 깁스 샘플링으로 결합 사후분포 추론

$$p(\theta, \sigma^2|y, s^2)$$

Posterior predictive distribution

$\theta_{new}|\mu,\tau^2 \sim N(\mu,\tau^2)$ $Y_{new}|\theta_{new},\sigma^2 \sim N(\theta_{new},\sigma^2)$ parametric random-effect model

$$f(y_{new}|y,s^2) = \iint \underbrace{f(y_{new}|\theta,\sigma^2)}_{\text{새로운 환자에 대한 불확실성}} \times \underbrace{f(\theta,\sigma^2|y,s^2)}_{\text{결합 사후밀도}} d\theta d\sigma^2$$

- 즉, 모수들이 주어졌을 때 새로운 개인의 예측분포는 하나의 정규분포로 표현

$\theta_{new}|G \sim G$ $G \sim DP(\alpha, G_0)$ $G = \sum_{h=1}^{\infty} \pi_h \delta_{\gamma h}$ Dirichlet process

$$f(y_{new}|y,s^2) = \underbrace{\iint \left[\sum_{h=1}^{\infty} \pi_h \phi(y_{new}|\gamma_h,\sigma^2)\right]}_{\text{DP에 따른 정규 혼합 예측 분포}} \underbrace{\Pi(dG,d\sigma^2|y,s^2)}_{\text{결합 사후분포}}$$

- 변동을 하나의 평균 주변에서만 설명하는 것이 아니라 다른 연구의 평균을 반영한 정규 혼합분포로 표현

NP-2

$$y_i \sim f\left(\theta_i, \frac{\sigma_i^2}{n_i}\right), \qquad \theta_i \sim G, \qquad G \sim DP(\alpha, G_0)$$

$$\sigma_i \sim G_\sigma, \qquad G_\sigma \sim DP(\alpha_\sigma, G_{0\sigma})$$

$$G_{0\sigma} = IG(\alpha_0, \beta_0)$$

	NP	**NP-2**
연구별 평균	$\theta_i \sim G$	$\theta_i \sim G$
평균에 대한 DP	$G \sim DP(\alpha, G_0)$	$G \sim DP(\alpha, G_0)$
연구내 분산	공통 σ^2	연구별 σ_i^2
표준편차에 대한 DP	없음	$G_\sigma \sim DP(\alpha_\sigma, G_{0\sigma})$
실제 연구내 분산의 이질성	허용하지 않음	허용

Simulation settings

1. Data generation

$$\theta_i \sim F_\theta,$$

$$F_\theta : Normal\ mixture,$$
$$Log - normal,$$
$$Gamma,$$

$$y_{ij} \sim N(\theta_i, \sigma_i^2)$$

2. Prior specifications

$$NP$$
$$\sigma \sim U(0,10), \alpha \sim gamma(1,1)$$
$$\tau \sim U(0,10), \mu \sim N(0,100)$$

$$NP2$$
$$\sigma_i \sim IG(\alpha_0, \beta_0),$$
$$\alpha_0 \sim IG(1,2), \qquad \beta_0 \sim IG(1,2)$$

3. Experimental conditions

Studies	Sample size	Replications	Methods
$k = 5,10,30$	$n_i = 100$	2,000	Freq, Bayes, Emp, Mix, NP, NP-2

Simulation results(Equal Within-study Variances)

TABLE 2 Data generated with equal within-study variances $\sigma^2 = 1.25$ for all three scenarios.

	Mixed normal		Log normal		Gamma	
Method	**95% RI[a]**	**Coverage[b]**	**95% RI**	**Coverage**	**95% RI**	**Coverage**
True range	**[5.17, 12.79]**		**[2.60, 16.90]**		**[0.07, 14.07]**	
$k = 5$						
NP	[5.97, 12.63]	0.89 (0.71, 0.98)	[3.33, 13.64]	0.82 (0.57, 0.97)	[0.40, 10.61]	0.81 (0.55, 0.99)
NP-2	[5.95, 12.55]	0.89 (0.71, 0.97)	[3.36, 13.66]	0.82 (0.55, 0.97)	[0.41, 10.65]	0.82 (0.54, 0.99)
Mix	[5.88, 12.59]	0.90 (0.72, 0.98)	[3.30, 13.70]	0.83 (0.56, 0.97)	[0.36, 10.73]	0.83 (0.56,0.99)
Freq	[5.65, 13.15]	0.93 (0.73, 0.99)	[1.46, 14.57]	0.91 (0.62, 1.00)	[−1.54, 11.54]	0.91 (0.59, 0.99)
Emp	[5.89, 12.91]	0.91 (0.72, 0.99)	[2.05, 13.98]	0.88 (0.59, 1.00)	[−0.95, 10.95]	0.88 (0.57, 0.99)
Bayes	[2.93, 15.81]	0.99 (0.81, 1.00)	[−4.56, 20.41]	0.99 (0.82, 1.00)	[−7.48, 17.41]	0.99 (0.77, 1.00)
$k = 10$						
NP	[5.60, 12.67]	0.92 (0.80, 0.98)	[2.99, 14.92]	0.89 (0.71, 0.98)	[0.17, 12.44]	0.90 (0.70, 0.99)
NP-2	[5.60, 12.69]	0.92 (0.80, 0.98)	[2.99, 14.91]	0.89 (0.71, 0.98)	[0.10, 12.28]	0.90 (0.72, 0.99)
Mix	[5.50, 12.70]	0.93 (0.81, 0.98)	[2.93, 15.06]	0.89 (0.71, 0.98)	[0.07, 12.41]	0.91 (0.72,0.99)
Freq	[5.58, 13.21]	0.94 (0.82, 0.99)	[1.20, 14.70]	0.93 (0.75, 0.99)	[−1.88, 11.91]	0.94 (0.75, 0.99)
Emp	[5.70, 13.10]	0.93 (0.81, 0.99)	[1.51, 14.42]	0.92 (0.73, 0.99)	[−1.57, 11.60]	0.93 (0.73, 0.99)
Bayes	[4.78, 13.98]	0.98 (0.86, 1.00)	[−0.67, 16.48]	0.96 (0.83, 1.00)	[−3.78, 13.72]	0.97 (0.81, 0.99)
$k = 30$						
NP	[5.31, 12.76]	0.94 (0.89, 0.97)	[2.80, 16.38]	0.93 (0.84, 0.98)	[0.004, 13.95]	0.95 (0.85, 0.99)
NP-2	[5.30, 12.77]	0.94 (0.89, 0.97)	[2.75, 16.72]	0.93 (0.85, 0.98)	[0.02, 14.10]	0.95 (0.86, 0.99)
Mix	[5.20, 12.80]	0.95 (0.90, 0.97)	[2.68, 17.21]	0.94 (0.85, 0.98)	[−0.05, 14.45]	0.95 (0.87,0.99)
Freq	[5.52, 13.26]	0.95 (0.89, 0.98)	[0.94, 15.05]	0.95 (0.87, 0.99)	[−2.11, 12.13]	0.95 (0.87, 0.99)
Emp	[5.56, 13.22]	0.95 (0.89, 0.98)	[1.04, 14.95]	0.95 (0.86, 0.99)	[−2.01, 12.03]	0.95 (0.88, 0.99)
Bayes	[5.32, 13.48]	0.96 (0.90, 0.99)	[0.44, 15.61]	0.96 (0.88, 0.99)	[−2.61, 12.69]	0.96 (0.88, 0.99)

Simulation results(Unequal Variances)

TABLE 3 Data generated with unequal within-study variances, where σ_i were generated from a truncated normal distribution with a mean of 1, the left truncation point equal to 0.5, and the right truncation point equal to 2.5.

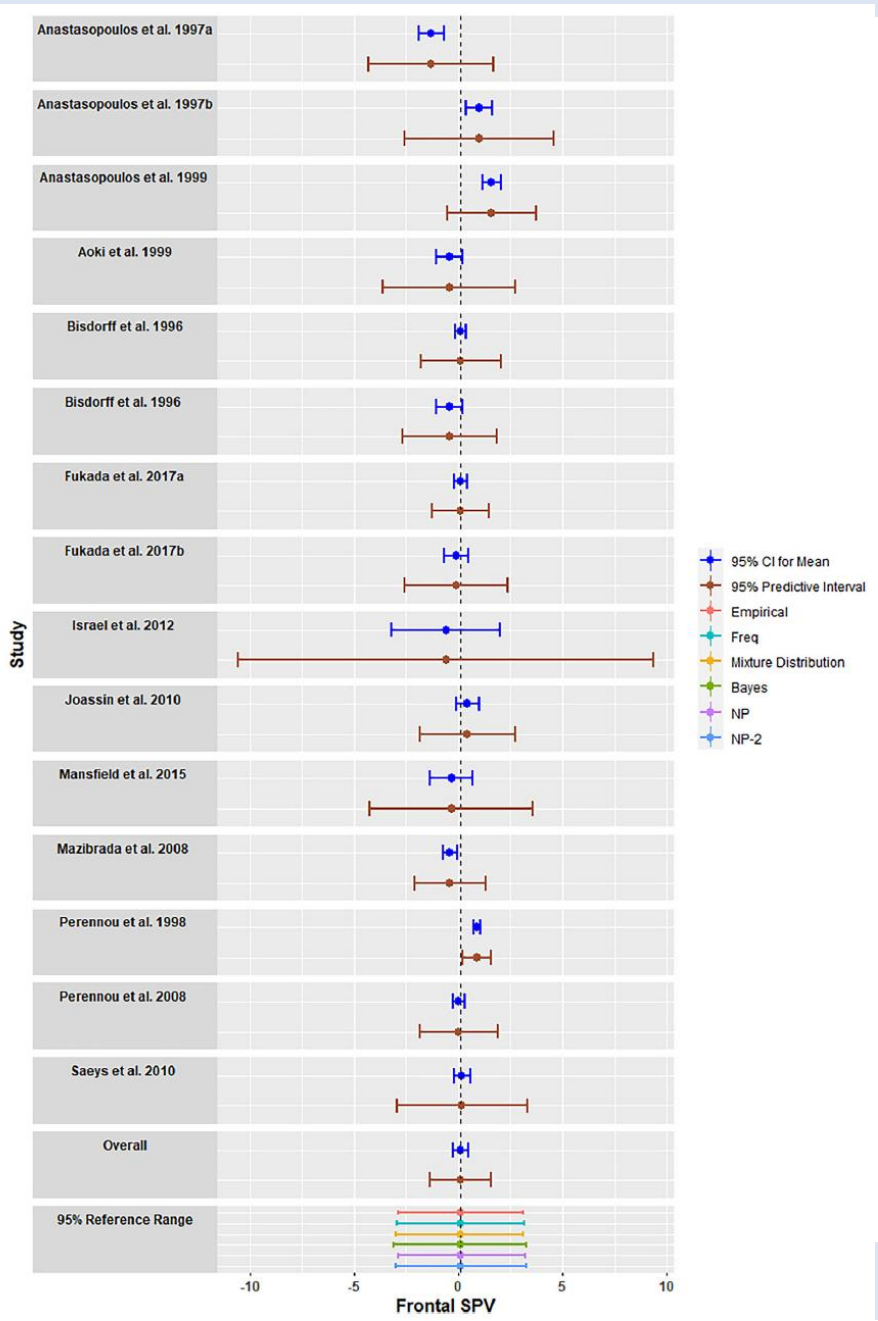
	$k = 5$		$k = 10$		$k = 30$	
	95% RI[a]	Coverage[b]	95% RI	Coverage	95% RI	Coverage
True range	[4.82, 13.36]		[4.82, 13.36]		[4.82, 13.36]	
NP	[5.47, 13.15]	0.91 (0.74, 0.98)	[5.20, 13.22]	0.93 (0.83, 0.98)	[4.95, 13.29]	0.94 (0.90, 0.97)
NP-2	[5.51, 13.09]	0.91 (0.74, 0.97)	[5.18, 13.20]	0.93 (0.83, 0.97)	[4.93, 13.27]	0.94 (0.90, 0.97)
Mix	[5.35, 13.14]	0.91 (0.75, 0.98)	[5.07, 13.29]	0.93 (0.82, 0.98)	[4.85, 13.32]	0.95 (0.90, 0.97)
Freq	[5.16, 13.59]	0.93 (0.77, 0.99)	[5.15, 13.67]	0.94 (0.82, 0.99)	[5.12, 13.67]	0.95 (0.90, 0.99)
Emp	[5.39,13.36]	0.92 (0.75, 0.99)	[5.26, 13.55]	0.94 (0.82, 0.98)	[5.16, 13.63]	0.95 (0.90, 0.99)
Bayes	[2.51,16.36]	0.99 (0.86, 1.00)	[4.40, 14.40]	0.97 (0.86, 1.00)	[4.95, 13.86]	0.96 (0.91, 0.98)

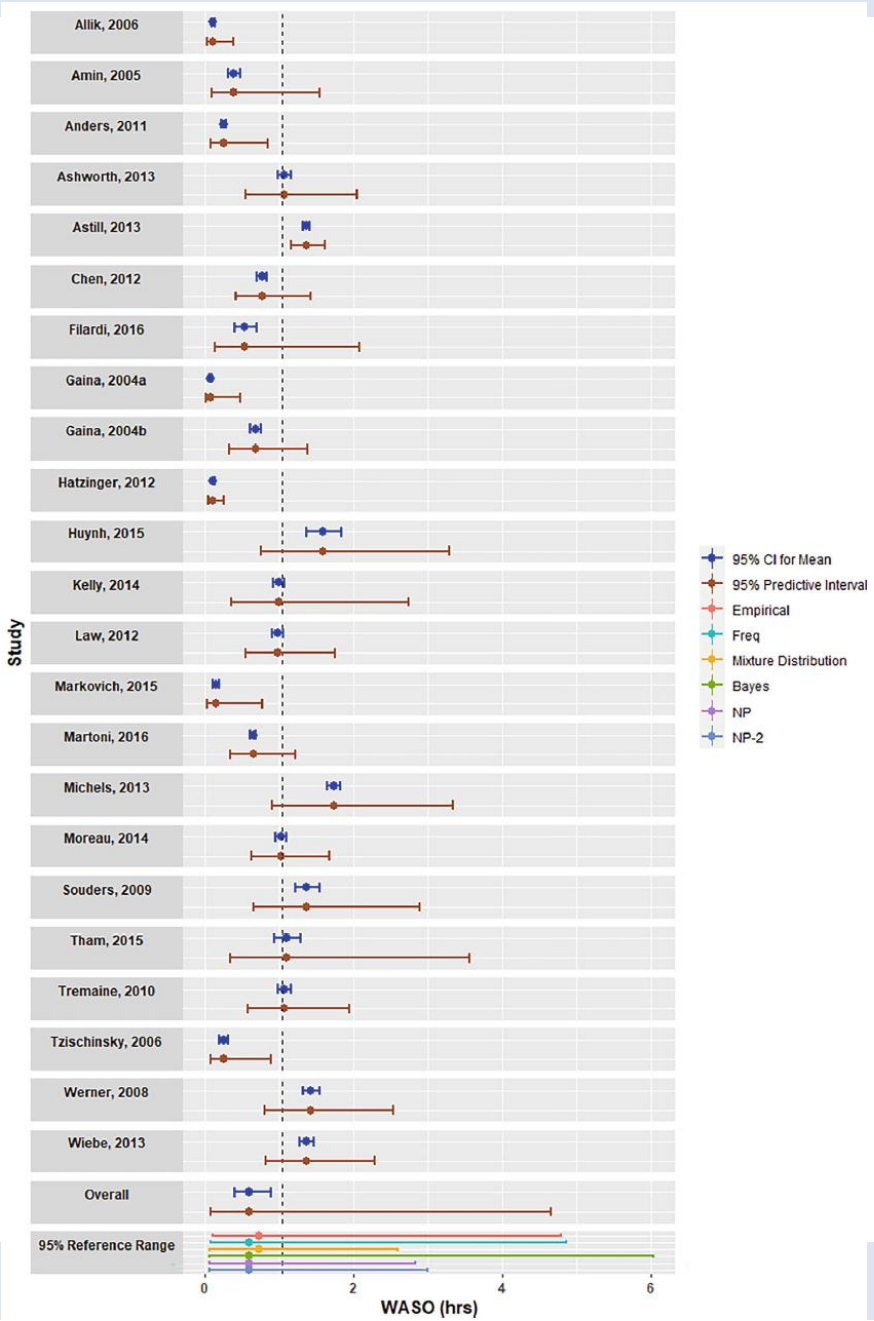
Simulation results(Robustness to Outliers)

TABLE 4 Simulation results for mixed normal adding outliers: Outliers defined as values smaller than $Q1 - 1.5 \times IQR$ or larger than $Q3 + 1.5 \times IQR$.

	$k = 5$		$k = 10$		$k = 30$	
	95% RI[a]	Coverage[b]	95% RI	Coverage	95% RI	Coverage
True range	[5.17, 12.79]		[5.17, 12.79]		[5.17, 12.79]	
NP	[5.77,12.72]	0.91 (0.74, 0.98)	[5.47,12.83]	0.93 (0.83, 0.98)	[5.20,12.90]	0.95 (0.90, 0.98)
NP-2	[5.76,12.73]	0.91 (0.74, 0.98)	[5.48,12.86]	0.94 (0.83, 0.98)	[5.17,12.92]	0.95 (0.90, 0.98)
Mix	[5.70, 12.80]	0.91 (0.75, 0.98)	[5.39,12.87]	0.94 (0.83, 0.98)	[5.13,12.93]	0.95 (0.91, 0.98)
Freq	[5.47, 13.29]	0.92 (0.75, 0.99)	[5.45,13.33]	0.95 (0.83, 0.99)	[5.41,13.35]	0.96 (0.90, 0.98)
Emp	[5.70, 13.10]	0.95 (0.89, 0.98)	[5.57,12.21]	0.94 (0.83, 0.99)	[5.44,13.32]	0.95 (0.90, 0.98)
Bayes	[2.77, 15.91]	0.99 (0.95, 1)	[4.86,14.07]	0.94 (0.83, 0.98)	[5.22,13.56]	0.97 (0.91, 0.99)

Real data analysis





Discussion

- DP 기반 메타분석을 새로운 건강한 개인의 참고구간 추정 문제에 적용하였으며 연구 내 분산의 이질성을 반영하기 위해서도 적용하였음

$$\theta_i \sim G, \qquad G \sim DP(\alpha, G_0)$$
$$\sigma_i \sim G_\sigma, \qquad G_\sigma \sim DP(\alpha_\sigma, G_{0\sigma})$$

- DP를 도입함으로써 연구 간 정규성 가정을 완화하였으며 연구 내 이분산성과 분산 추정의 불확실성을 반영

- 실험에서 우수하다고 나온 것은 아니지만 이를 통해 연구별 요약통계량으로부터 개인 수준의 참고구간을 추정하는 베이지안 비모수 모형을 제안한 점이 핵심

Thank you for
your attention

NP에서의 표본분산

$$(n_i - 1)s_i^2 \sim gamma\left(\frac{n_i - 1}{2}, \frac{1}{2\sigma^2}\right), \qquad \sigma \sim U(0,10)$$