논문 리뷰

SHARPNESS-AWARE MINIMIZATION FOR EFFICIENTLY IMPROVING GENERALIZATION

Pierre Foret *
Google Research
pierre.pforet@gmail.com

Ariel Kleiner
Google Research
akleiner@gmail.com

Hossein Mobahi
Google Research
hmobahi@google.com

Behnam Neyshabur
Blueshift, Alphabet
neyshabur@google.com

일반화를 위한 샤프니스 인지 최소화

확률적 경사하강법 (SGD)

배경 개념 · 미니배치 SGD

- 작은 데이터 묶음(미니배치)으로 현재 손실과 기울기를 계산
- 기울기의 반대 방향으로 가중치를 반복 업데이트

$$w' = w - \eta g$$

현재 가중치 − 학습률 × 기울기 = 다음 가중치

w: 현재 가중치 · w′: 다음 가중치 · η: 학습률

g: 현재 미니배치 손실의 기울기 (gradient)

SGD는 현재 위치에서 손실을 낮춤 → SAM은 주변 손실까지 고려

논문 초록

Abstract · 문제 → 방법 → 결과

문제

낮은 훈련 손실만으로는
좋은 일반화 성능을 보장하기 어려움

방법

현재 손실과 주변 손실 증가를
함께 고려하는 SAM 제안

결과

이미지 분류·미세조정 성능 개선
라벨 노이즈 환경에서도 강건성 확인

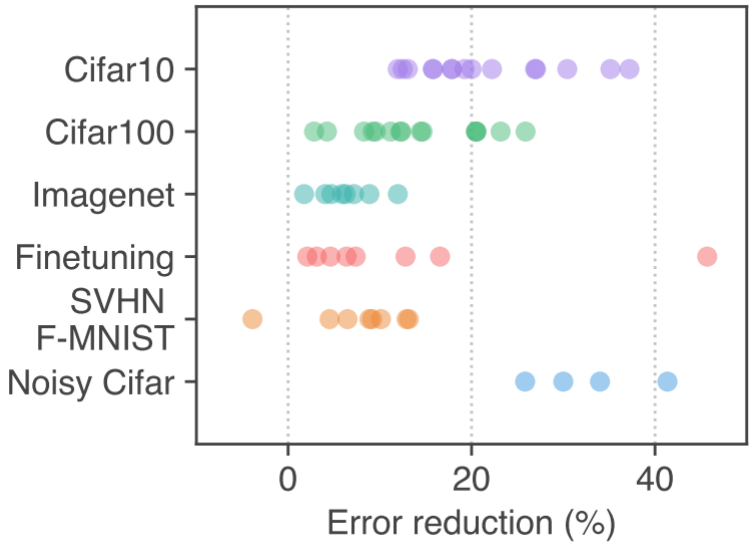


Figure 1 여러 실험의 오류 감소율

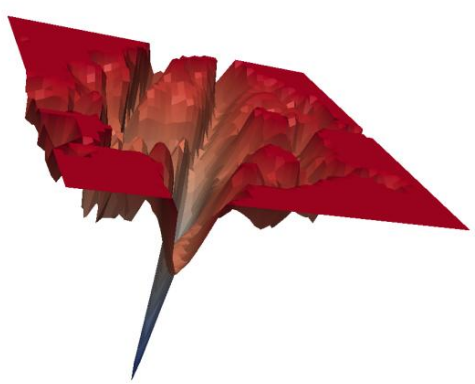
SAM의 용도와 연구 동기

§1 Introduction · 일반화 성능 개선

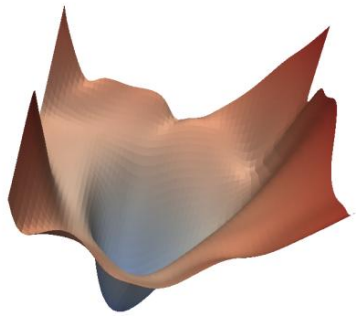
목적: 처음 보는 데이터에서도 잘 작동하는 모델 학습

훈련 데이터의 좋은 성능이 테스트 성능으로 이어지지 않는 문제

적용: 새 모델 학습 · 사전학습 모델의 미세조정



SGD



SAM

가중치가 조금 변해도 손실이 낮게 유지되는 해를 탐색

Foret et al. · ICLR 2021

SAM의 목적함수

§2 Sharpness-Aware Minimization

$$\min_{\boldsymbol{w}} L_S^{SAM}(\boldsymbol{w}) + \lambda ||\boldsymbol{w}||_2^2 \quad \text{where} \quad L_S^{SAM}(\boldsymbol{w}) \triangleq \max_{||\boldsymbol{\epsilon}||_p \leq \rho} L_S(\boldsymbol{w} + \boldsymbol{\epsilon}), \tag{1}$$

안쪽 max: 주변의 최악 손실　　바깥 min: 그 손실을 낮추는 가중치

주변의 최악 손실 = 현재 손실 + sharpness

w: 가중치　　S: 훈련 데이터　　L_s: 평균 훈련 손실

ε: 가중치 변화　　ρ: 허용 반경　　p: 노름의 종류 (주로 2)

λ: 정규화 강도　　$\|w\|_2^2$: 가중치 크기에 대한 페널티

낮은 손실과 작은 주변 손실 증가를 함께 추구

SAM 알고리즘

§2 · 식 (2)–(3) · Algorithm 1

① 현재 위치의 기울기 (gradient)

$$g = \nabla L(w)$$

② 손실 증가 방향으로 작은 이동

$$\hat{\varepsilon} = \rho g / \|g\|_2$$

③ 이동한 위치에서 gradient 계산

$$w' = w - \eta \nabla L(w + \hat{\varepsilon})$$

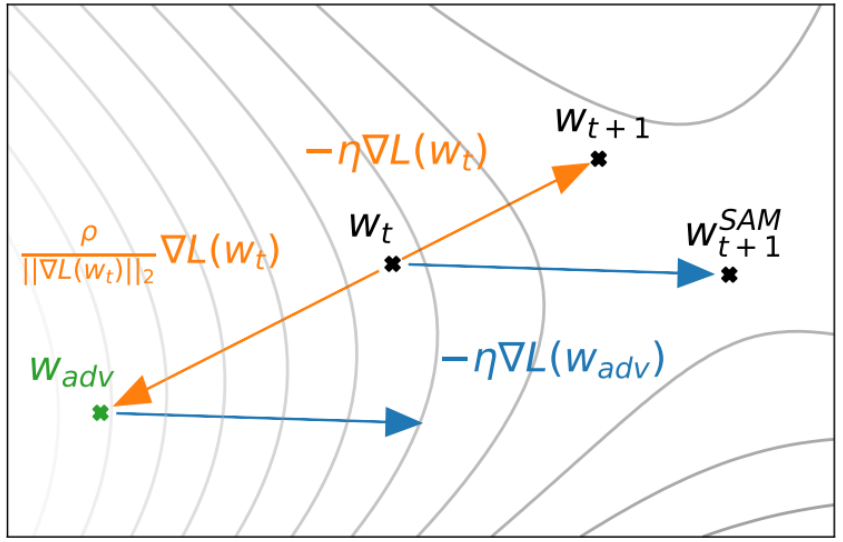


Figure 2 | SGD와 SAM의 업데이트 비교

L: 미니배치 평균 손실 · w′: 다음 가중치 · ε̂: 근사 변화 · η: 학습률

두 번의 gradient 계산 → 원래 가중치를 업데이트

실험 설정과 CIFAR 결과

§3.1 · Table 1 원본 발췌

- CIFAR-10·100 · 사전학습 없이 기존 증강·정규화와 결합
- SGD는 기본·두 배 epoch 중 좋은 결과 사용

		CIFAR-10		CIFAR-100	
Model	Augmentation	SAM	SGD	SAM	SGD
WRN-28-10 (200 epochs)	Basic	**2.7**$_{\pm 0.1}$	3.5$_{\pm 0.1}$	**16.5**$_{\pm 0.2}$	18.8$_{\pm 0.2}$
WRN-28-10 (200 epochs)	Cutout	**2.3**$_{\pm 0.1}$	2.6$_{\pm 0.1}$	**14.9**$_{\pm 0.2}$	16.9$_{\pm 0.1}$
WRN-28-10 (200 epochs)	AA	**2.1**$_{\pm <0.1}$	2.3$_{\pm 0.1}$	**13.6**$_{\pm 0.2}$	15.8$_{\pm 0.2}$
PyramidNet+ShakeDrop	Basic	**2.1**$_{\pm 0.1}$	2.5$_{\pm 0.1}$	**13.3**$_{\pm 0.2}$	14.5$_{\pm 0.1}$
PyramidNet+ShakeDrop	Cutout	**1.6**$_{\pm <0.1}$	1.9$_{\pm 0.1}$	**11.3**$_{\pm 0.1}$	11.8$_{\pm 0.2}$
PyramidNet+ShakeDrop	AA	**1.4**$_{\pm <0.1}$	1.6$_{\pm <0.1}$	**10.3**$_{\pm 0.1}$	10.6$_{\pm 0.1}$

오류율(%) ↓ · 평균 ± 95% 신뢰구간, 5회 실행 · AA: AutoAugment

강한 정규화를 사용한 모델에서도 추가 개선

ImageNet 결과

§3.1 · Table 2 원본

같은 모델·같은 epoch의 top-1·top-5 오류율 비교

Model	Epoch	SAM		Standard Training (No SAM)	
		Top-1	Top-5	Top-1	Top-5
ResNet-50	100	**22.5**$_{\pm 0.1}$	6.28$_{\pm 0.08}$	22.9$_{\pm 0.1}$	6.62$_{\pm 0.11}$
	200	**21.4**$_{\pm 0.1}$	5.82$_{\pm 0.03}$	22.3$_{\pm 0.1}$	6.37$_{\pm 0.04}$
	400	**20.9**$_{\pm 0.1}$	5.51$_{\pm 0.03}$	22.3$_{\pm 0.1}$	6.40$_{\pm 0.06}$
ResNet-101	100	**20.2**$_{\pm 0.1}$	5.12$_{\pm 0.03}$	21.2$_{\pm 0.1}$	5.66$_{\pm 0.05}$
	200	**19.4**$_{\pm 0.1}$	4.76$_{\pm 0.03}$	20.9$_{\pm 0.1}$	5.66$_{\pm 0.04}$
	400	**19.0**$_{\pm <0.01}$	4.65$_{\pm 0.05}$	22.3$_{\pm 0.1}$	6.41$_{\pm 0.06}$
ResNet-152	100	**19.2**$_{\pm <0.01}$	4.69$_{\pm 0.04}$	20.4$_{\pm <0.0}$	5.39$_{\pm 0.06}$
	200	**18.5**$_{\pm 0.1}$	4.37$_{\pm 0.03}$	20.3$_{\pm 0.2}$	5.39$_{\pm 0.07}$
	400	**18.4**$_{\pm <0.01}$	4.35$_{\pm 0.04}$	20.9$_{\pm <0.0}$	5.84$_{\pm 0.07}$

단위: % · 낮을수록 좋음 · 평균 ± 95% 신뢰구간, 5회 실행

장기 학습에서도 SAM의 성능 개선이 이어진다

미세조정과 라벨 노이즈

§3.2–3.3 · Tables 3–4 원본 발췌

미세조정: EfficientNet-b7

Dataset	EffNet-b7 + SAM	EffNet-b7
FGVC_Aircraft	$6.80_{\pm 0.06}$	$8.15_{\pm 0.08}$
Flowers	$\mathbf{0.63}_{\pm 0.02}$	$1.16_{\pm 0.05}$
Oxford_IIIT_Pets	$\mathbf{3.97}_{\pm 0.04}$	$4.24_{\pm 0.09}$
Stanford_Cars	$5.18_{\pm 0.02}$	$5.94_{\pm 0.06}$
CIFAR-10	$\mathbf{0.88}_{\pm 0.02}$	$0.95_{\pm 0.03}$
CIFAR-100	$\mathbf{7.44}_{\pm 0.06}$	$7.68_{\pm 0.06}$
Birdsnap	$\mathbf{13.64}_{\pm 0.15}$	$14.30_{\pm 0.18}$
Food101	$7.02_{\pm 0.02}$	$7.17_{\pm 0.03}$
ImageNet	$15.14_{\pm 0.03}$	15.3

Table 3 · EffNet-b7 열 발췌 · 오류율(%) ↓

라벨 노이즈: CIFAR-10

Method	Noise rate (%)			
	20	40	60	80
Sanchez et al. (2019)	94.0	92.8	90.3	74.1
Zhang & Sabuncu (2018)	89.7	87.6	82.7	67.9
Lee et al. (2019)	87.1	81.8	75.4	-
Chen et al. (2019)	89.7	-	-	52.3
Huang et al. (2019)	92.6	90.3	43.4	-
MentorNet (2017)	92.0	91.2	74.2	60.0
Mixup (2017)	94.0	91.5	86.8	76.9
MentorMix (2019)	**95.6**	**94.2**	91.3	**81.0**
SGD	84.8	68.8	48.2	26.2
Mixup	93.0	90.0	83.8	70.2
Bootstrap + Mixup	93.3	92.0	87.6	72.0
SAM	95.1	93.4	90.5	77.9
Bootstrap + SAM	95.4	**94.2**	**91.8**	79.9

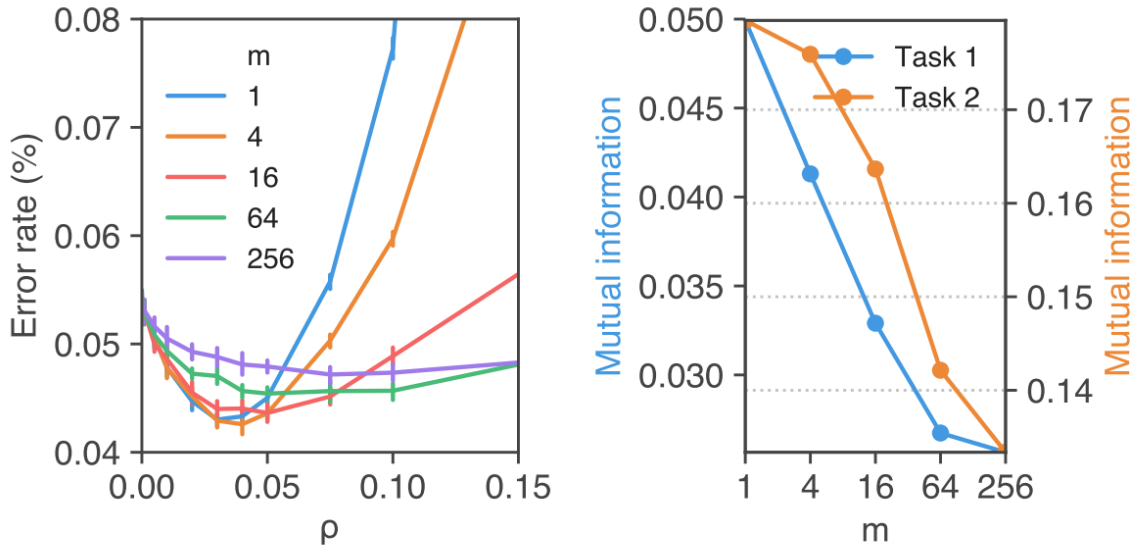
Table 4 · 전체 노이즈 비율 · 정확도(%) ↑

미세조정·라벨 노이즈 환경에서도 효과 확인

m-sharpness와 일반화

§4.1 · Figure 3 가운데·오른쪽

m = 하나의 perturbation을 계산하는 데이터 수

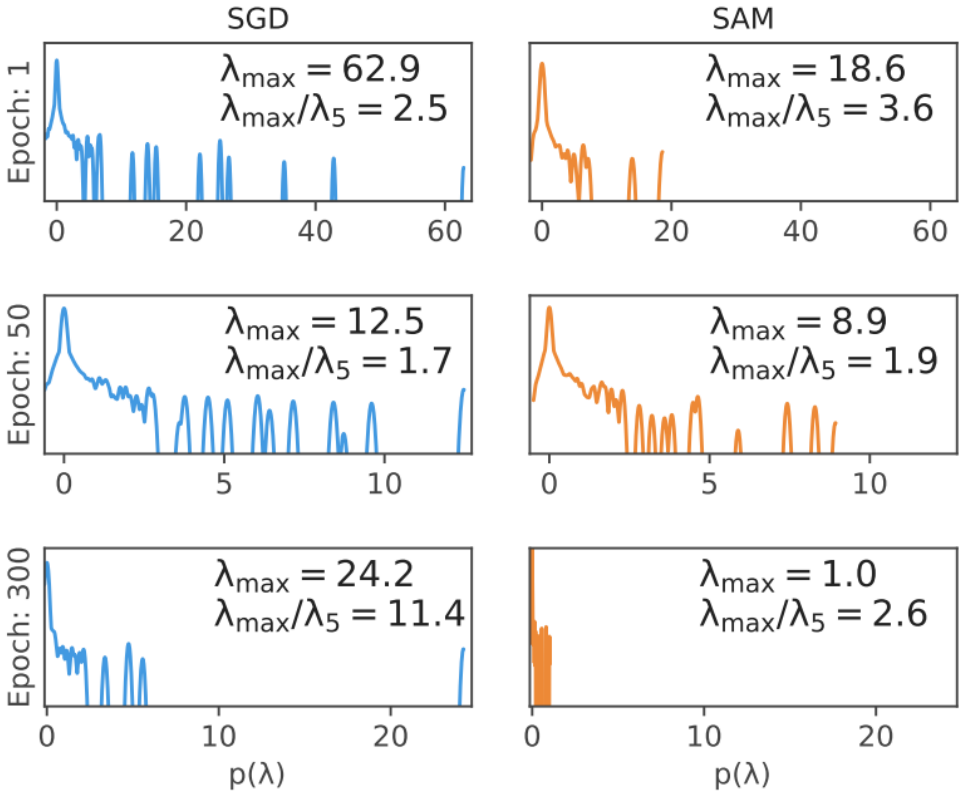


왼쪽: ρ와 m에 따른 오류율 | 오른쪽: 일반화 격차와의 상호정보량

샤프니스를 계산하는 데이터 묶음의 크기도 중요

실제로 더 평평한 해를 찾는가

§4.2 · Figure 3 왼쪽



헤시안 (Hessian)

손실의 2차 미분 행렬
→ 국소 곡률을 측정

마지막 시점의 최대 고유값

SGD 24.2 → SAM 1.0

CIFAR-10 · 배치 정규화 제외

해당 실험에서 SAM은 낮은 곡률의 영역에 도달

근사 방법의 타당성

부록 C.4–C.5 · Figures 4·6

2차 항 생략

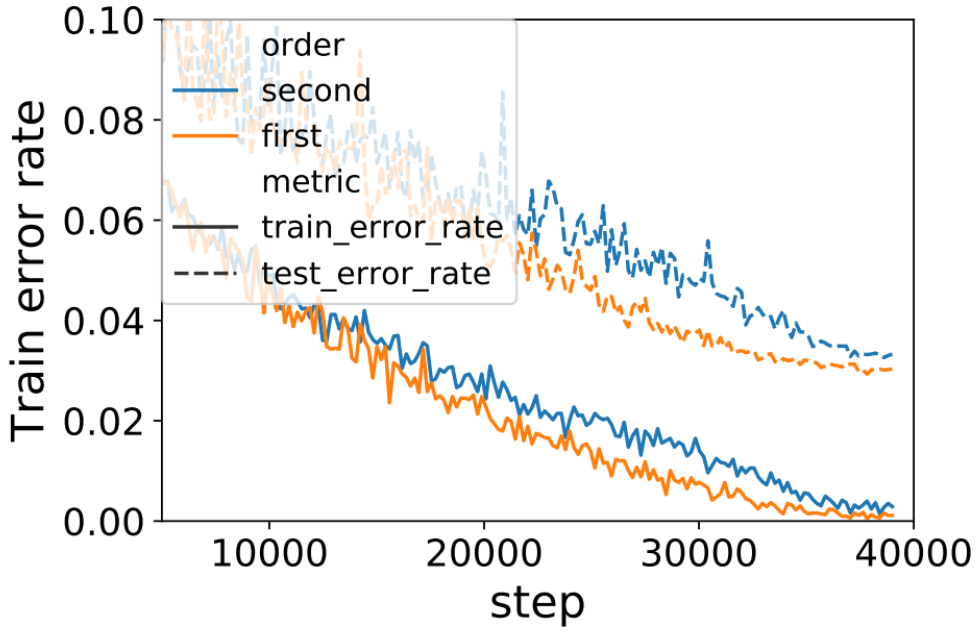


Figure 4 · 해당 실험에서 1차 근사가 우수

Perturbation의 방향과 크기

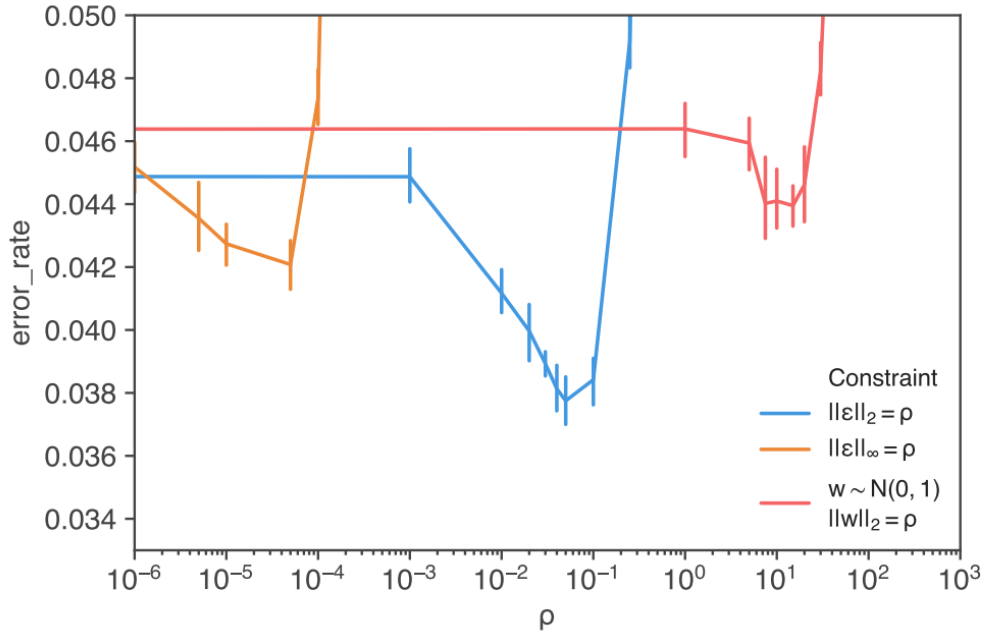


Figure 6 · L_2 적대적 변화가 우수

더 정확한 내부 계산이 항상 더 좋은 일반화로 이어지지는 않음

결론과 향후 연구

§5 Related Work · §6 Discussion and Future Work

주변의 최악 손실을 낮추는 학습 목적

두 번의 gradient 계산으로 구현

- 기존 연구와의 차이: 계산 가능한 근사와 다양한 실험 검증
- 이론 과제: 작은 데이터 묶음의 sharpness와 일반화 연결
- 확장 방향: 강건 학습·준지도학습에 SAM 결합

낮은 훈련 손실을 넘어, 주변에서도 안정적인 해를 탐색

비판적 평가

리뷰 관점 · 본문과 부록에 근거한 해석

평가 항목	확인할 질문
계산 비용	같은 epoch인가, 같은 계산량인가?
튜닝과 재현	ρ·m·깨끗한 검증 라벨의 조건이 같은가?
주장의 범위	성능 개선과 보편적인 인과 설명을 구분했는가?

강점: 기존 모델에 적용하기 쉽고, 여러 실험으로 검증

실용적 성과는 분명하지만, 일반화 원리의 완전한 설명은 남아 있다

보충 1. 일반화 상계의 가정

부록 A · PAC-Bayes 기반 일반화 상계

$$L^{D}(w) \leq \max L_{S}(w + \varepsilon) + h(\|w\|_2^2 / \rho^2)$$

최대화 범위: $\|\varepsilon\|_2 \leq \rho$

모집단 손실 ≤ 주변의 최악 훈련 손실 + 복잡도 항

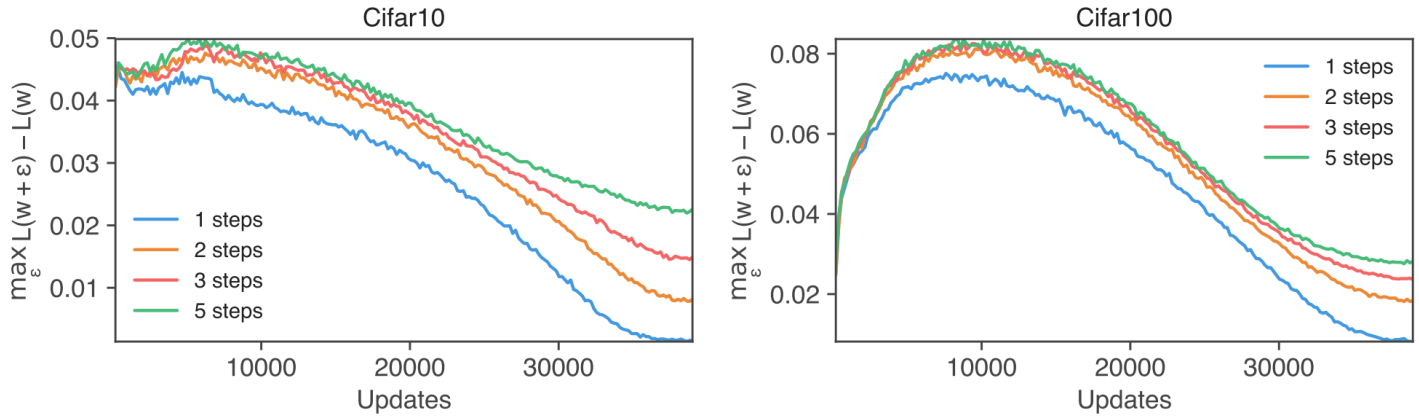
- 가우시안 perturbation이 모집단 손실을 평균적으로 줄이지 않는다는 가정
- 복잡도 항에는 표본 수·파라미터 수·가중치 크기 등이 관여
- h를 $\lambda\|w\|_2^2$로 대체 → 상계에서 동기를 얻은 실용적 목적함수

D: 데이터 분포 · S: 훈련 표본 · h: 복잡도 항 · w·ε·ρ: 본문과 동일

Foret et al. · ICLR 2021

보충 2. 내부 최대화 반복 횟수

부록 C.6 · Figure 7 · Table 11 원본



Number of projected gradient steps	CIFAR-10		CIFAR-100	
	Test error	Estimated sharpness	Test error	Estimated sharpness
1	$2.77_{\pm 0.03}$	$0.17_{\pm 0.03}$	$16.72_{\pm 0.08}$	$0.82_{\pm 0.05}$
2	$2.76_{\pm 0.03}$	$0.82_{\pm 0.03}$	$16.59_{\pm 0.08}$	$1.83_{\pm 0.05}$
3	$2.73_{\pm 0.04}$	$1.49_{\pm 0.05}$	$16.62_{\pm 0.09}$	$2.36_{\pm 0.03}$
5	$2.77_{\pm 0.03}$	$2.26_{\pm 0.05}$	$16.60_{\pm 0.06}$	$2.82_{\pm 0.04}$

Table 11 · Test error: % · 평균 ± 표준편차, 20회 실행

추가 반복은 계산량 증가 · 테스트 성능 이득은 제한적