WILDS: A Benchmark of in-the-Wild Distribution Shifts

Pang Wei Koh, Shiori Sagawa, Henrik Marklund, Sang Michael Xie, Marvin Zhang, Akshay Balsubramani, Weihua Hu, Michihiro Yasunaga, Richard Lanas Phillips, Irena Gao, Tony Lee, Etienne David, Ian Stavness, Wei Guo, Berton Earnshaw, Imran Haque, Sara M Beery, Jure Leskovec, Anshul Kundaje, Emma Pierson, Sergey Levine, Chelsea Finn, Percy Liang *Proceedings of the 38th International Conference on Machine Learning*, PMLR 139:5637-5664, 2021.

July 22, 2021

오서영

Abstract

- 실제 환경에서는 훈련 분포와 테스트 분포가 달라지는 경우가 많으며, 이로 인해 모델 성능이 크게 저하됨
- 그러나 기존의 머신러닝 벤치마크는 주로 분포를 같게 가정
- 이에, 저자들은 현실에서 발생하는 distribution shift를 반영한 10개 데이터셋 벤치마크 제안
- 표준 학습 모델과 기존 distribution shift 알고리즘들은 모든 데이터셋에서 ID보다 낮은 ODD 성능을 보임
- 또한, 데이터 load, 기본 모델, 하이퍼파라미터, 평가 등을 표준화한 오픈소스 패키지와 리더보드를 제공

- 벤치마크 : 여러 방법을 동일한 조건에서 비교, 평가하기 위해 표준화된 실험 환경

Introduction

- 기존 벤치마크의 한계
  - 훈련자료와 테스트자료를 무작위로 분할함
    - 이러한 자료는 분포는 유사하지만, 새로운 지역/기관/시점 등에서 잘 작동하는지에 대한 확인은 어려움
  - 기존의 distribution shift 연구는 색상이나 배경을 변경하거나 이미지에 노이즈를 추가하는 방법으로 변화를 주었음
    - 이러한 벤치마크 방법은 shift 원인을 통제할수 있지만 현실에서의 복합적인 변화를 반영할 수 없고, 실제 데이터셋 간 변화에도 강건하다는 보장이 없음.

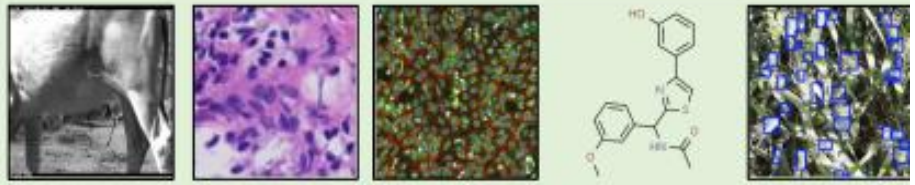
- WILDS의 차이점, 데이터셋 선정 기준
  - 차이점 : 노이즈 추가가 아닌 현실에서 발생하는 변화를 사용함
  1. 분포 변화에 따른 성능 저하가 있는지?
  2. 현실세계와 연관성이 있는지?
  3. 여러 훈련 도메인과 메타데이터를 통한 개선 가능성이 있는지?

Problem Settings

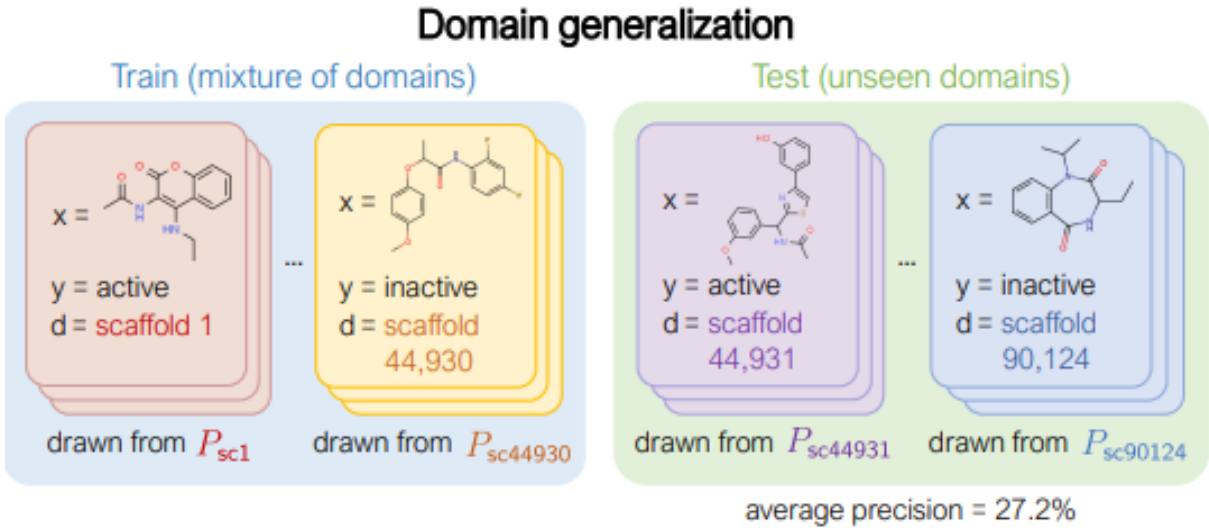
- 도메인 집합을 $\mathcal{D} = \{1, \ldots, D\}$로 정의하고, 전체 데이터 분포는 각 도메인의 분포 $\mathrm{P_d}$가 혼합된 형태로 표현
  - 입력값 x, 예측 대상 y, 도메인 d
  - 데이터 분포 P_d, 전체 데이터에서 도메인 d가 차지하는 비율 q_d
  - 훈련분포 $P^{train} = \sum q_d^{train} P_d$, 테스트분포 $P^{test} = \sum q_d^{test} P_d$
  - 훈련분포에 포함된 도메인 집합 $\mathcal{D}^{train} = \{d \in \mathcal{D} | q_d^{train} > 0\}$

- OOD 성능과 비교할 ID 기준 성능의 구성 방법
  1. Fixed-train
  2. Fixed-test
  3. Randomized
  4. Average

Domain Generalization datasets

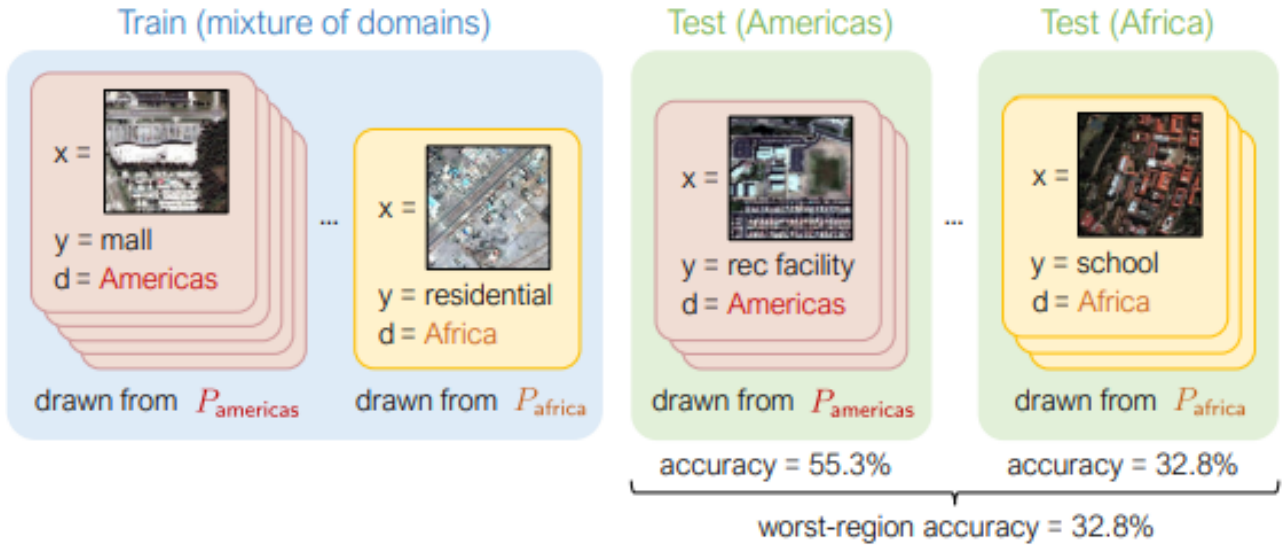
	Domain generalization				
Dataset	**iWildCam**	**Camelyon17**	**RxRx1**	**OGB-MolPCBA**	**GlobalWheat**
Input (x)	camera trap photo	tissue slide	cell image	molecular graph	wheat image
Prediction (y)	animal species	tumor	perturbed gene	bioassays	wheat head bbo
Domain (d)	camera	hospital	batch	scaffold	location, time
# domains	323	5	51	120,084	47
# examples	203,029	455,954	125,510	437,929	6,515
Train example					
Test example					
Adapted from	Beery et al. 2020	Bandi et al. 2018	Taylor et al. 2019	Hu et al. 2020	David et al. 2021

- 훈련과 테스트에서 사용되는 domain이 겹치지 않는 데이터셋
- 학습 과정에 없던 새로운 도메인에 일반화하는 것이 목표



Subpopulation shift dataset

Subpopulation shift
CivilComments
online comment
x toxicity
demographic
16
448,000
What do Black and LGBT people have to do with bicycle licensing?
As a Christian, I will not be patronizing any of those businesses.
Borkan et al. 2019



- 테스트에 등장하는 모든 도메인이 훈련에 포함되지만, 각 도메인이 차지하는 비율이 달라지는 경우
- 평균 성능이 아닌 가장 성능이 낮은 도메인의 성능 평가

Hybrid datasets

Domain generalization + subpopulation shift			
FMoW	PovertyMap	Amazon	Py150
satellite image	satellite image	product review	code
land use	asset wealth	sentiment	autocomplete
time, region	country, rural-urban	user	git repository
16 x 5	23 x 2	2,586	8,421
523,846	19,669	539,502	150,000
		Overall a solid package that has a good quality of construction for the price.	`import numpy as np … norm=np.___`
		I *loved* my French press, it's so perfect and came with all this fun stuff!	`import subprocess as sp p=sp.Popen() stdout=p.___`
Christie et al. 2018	Yeh et al. 2020	Ni et al. 2019	Raychev et al. 2016

- 새로운 도메인에 대한 일반화와 특정 도메인의 성능 평가를 동시에 고려하기 위한 데이터셋
- 이전의 데이터셋처럼 하나의 변화가 존재하기 보다, 시간/지역/집단 변화가 함께 나타날 수 있는 경우

Experiments

- Default model
  - 이미지 데이터 : ResNet, DenseNet
  - 텍스트 데이터 : DistilBERT
  - 분자그래프 : Graph Isomorphism Network(GIN)
  - 객체 탐지 : Faster R-CNN

- 비교 대상 알고리즘
  - ERM : 전체 train data의 평균 손실 최소화하는 방향으로 학습
  - CORAL : 각 도메인에서 추출된 feature의 평균,공분산이 유사하도록 학습
  - IRM : 여러 도메인에서 공통으로 유효한 예측 규칙을 학습
  - Group DRO : 가장 손실이 큰 집단의 손실을 최소화하는 방향으로 학습

Performance Drops under Distribution Shifts

Dataset	Metric	In-distribution type	In-distribution	Out-of-distribution
iWildCam2020-wilds	Macro F1	Fixed-train	47.0 (1.4)	31.0 (1.3)
Camelyon17-wilds	Average accuracy	Fixed-train	93.2 (5.2)	70.3 (6.4)
RxRx1-wilds	Average accuracy	Fixed-test	39.8 (0.2)	29.9 (0.4)
OGB-MolPCBA	Average AP	Randomized	34.4 (0.9)	27.2 (0.3)
GlobalWheat-wilds	Average domain accuracy	Fixed-test	64.8 (0.4)	48.4 (1.8)
CivilComments-wilds	Worst-group accuracy	Average	92.2 (0.1)	56.0 (3.6)
FMoW-wilds	Worst-region accuracy	Fixed-test	48.6 (0.9)	32.3 (1.3)
PovertyMap-wilds	Worst-U/R Pearson R	Fixed-test	0.60 (0.06)	0.45 (0.06)
Amazon-wilds	10th percentile accuracy	Average	71.9 (0.1)	53.8 (0.8)
Py150-wilds	Method/class accuracy	Fixed-train	75.4 (0.4)	67.9 (0.1)

분포 변화가 발생했을 때 ID 성능과 OOD 성능 비교 표

- 모든 데이터셋에서 OOD 성능이 ID 성능보다 낮게 나타남
- 즉, 실제 환경의 분포 변화가 표준 모델의 일반화 성능을 일관되게 저하시킴
- Fixed-test 비교에서는 OOD 분포의 데이터를 훈련에 포함한 모델이 OOD에서도 높은 성능을 보임
- 따라서, OOD 성능 저하는 훈련과 테스트 간 분포 차이가 원인임을 알 수 있음

Comparison of Robust Training Algorithms

Dataset	Setting	ERM	CORAL	IRM	Group DRO
iWildCam2020-wilds	Domain gen.	31.0 (1.3)	**32.8 (0.1)**	15.1 (4.9)	23.9 (2.1)
Camelyon17-wilds	Domain gen.	**70.3 (6.4)**	59.5 (7.7)	64.2 (8.1)	68.4 (7.3)
RxRx1-wilds	Domain gen.	**29.9 (0.4)**	28.4 (0.3)	8.2 (1.1)	23.0 (0.3)
OGB-MolPCBA	Domain gen.	**27.2 (0.3)**	17.9 (0.5)	15.6 (0.3)	22.4 (0.6)
GlobalWheat-wilds	Domain gen.	**49.2 (1.5)**	—	—	46.1 (1.6)
CivilComments-wilds	Subpop. shift	56.0 (3.6)	65.6 (1.3)	66.3 (2.1)	**70.0 (2.0)**
FMoW-wilds	Hybrid	**32.3 (1.3)**	31.7 (1.2)	30.0 (1.4)	30.8 (0.8)
PovertyMap-wilds	Hybrid	**0.45 (0.06)**	0.44 (0.06)	0.43 (0.07)	0.39 (0.06)
Amazon-wilds	Hybrid	**53.8 (0.8)**	52.9 (0.8)	52.4 (0.8)	53.3 (0.0)
Py150-wilds	Hybrid	**67.9 (0.1)**	65.9 (0.1)	64.3 (0.2)	65.9 (0.1)

기존의 distribution shift 알고리즘 성능 비교

- 대부분의 데이터셋에서 ERM 알고리즘이 가장 우수하였음
- 이론적으로 도메인에 강건한 표현을 학습하도록 설계된 방법들도 현실에서는 일관된 효과를 보이지 않음

Discussion

- Other applications and datasets
  - WILDS에 포함된 분야 외에도 자연어·음성, 교육, 로봇 등 다양한 분야에서도 분포 변화 발생이 가능함.
  - 기존의 10개 데이터셋 외의 다른 데이터셋도 검토하였으나, 성능 저하가 뚜렷하지 않아 데이터셋에서 제외함
  - 어떤 분포 변화가 모델 성능을 크게 저하시키는지 규명할 필요가 존재
- Other problem settings
  - Domain generalization, subpopulation shift 외에도 Unsupervised domain adaptation과 같은 다른 문제에도 활용 가능
  - 도메인 일반화 문제뿐만 아니라 테스트 환경의 추가 정보를 활용하는 다양한 분포 변화 연구에도 사용 가능
- Guidelines for algorithm development
  - 알고리즘을 비교하기 위해 WILDS에서 제공하는 표준 데이터 분할과 평가 지표를 사용
  - 외부 데이터를 사용하지 않고 기본 모델 구조 따르기
  - 적용 가능한 여러 WILDS 데이터셋에서 평가하기

Discussion

- Methods beyond training algorithms
  - 분포 변화에 대한 강건성을 높이는 방법
    - 새로운 모델 아키텍처 활용
    - 외부 데이터로 사전학습된 모델 활용
    - 더 효과적인 표현학습 방법 활용
  - 외부 데이터와 사전학습 모델 사용시 순수한 알고리즘 효과와 구분하기 위해 별도의 리더보드에서 관리
- Avoiding overfitting to the test distribution
  - WILDS의 일부 데이터셋은 OOD 테스트 도메인 수가 매우 적기 때문에 해당 데이터셋을 통해 알고리즘을 수정하면 과적합 가능성이 존재
  - 이에 모델 개발과 선택에는 OOD validation set을 사용하고, OOD test set은 최종 성능 평가에만 사용할 것을 제안